

陆取

联系方式: (+86) 15706281011

邮箱: jluluqu@163.com

出生年月: 1993 年 12 月

政治面貌: 中共党员

教育背景

- 2012.09-2016.06 吉林大学 计算机科学与技术学院 网络与信息安全专业 本科
- 2016.09-2019.06 中国科学院 信息工程研究所 计算机系统结构 硕士 (保研)

工作经历

- 2024.06-至今** 薯能生巧科技 (上海) 有限公司 (小红书) 搜推广引擎架构研发工程师
 - 负责小红书面向搜推广算法、工程的统一管控平台建设, 主导在离线一体化调度引擎设计与落地, 支撑在线服务与 AI 任务资源混部、弹性扩缩容及降本增效。
- 2023.11-2024.05** 上海科瀚杰科技有限公司 研发工程师
 - 负责内部组织管控系统的开发升级与迭代优化。
- 2019.07-2023.10** 上海寻梦信息技术有限公司 (拼多多) 推荐部门-Java 研发工程师
 - 负责推荐架构内部管控平台, 管理模型、场景代码、数据表等资源, 并基于相关元数据提供统一的分布式数据加载、数据路由框架, 支撑推荐系统高并发、高可用调度。

项目经历

搜推广一体化智能运维与索引管控平台

面向算法+工程的搜推广统一控制面, 实现“服务+数据”二层调度管控机制。成功支撑了搜推广 2000+ 核心服务和 3000+ 活跃索引运维。

- ❖ 标准化 DevOps 体系建设: 打通镜像构建、代码发布、云原生资源部署链路, 实现发布流程标准化和自动化。
- ❖ 服务与数据协同调度: 落地实现“服务与数据双维度驱动”流程, 将上游产出数据自动化接入训练→构建→同步→切换的多阶段 Pipeline, 实现索引产物与线上服务运行时的无缝挂钩, 核心操作由多步人工转化为自动化。
- ❖ 索引保障链路建设: 设计并实现索引链路保障体系, 针对 3000+ 索引任务实现 S0-S3 四级 SLA 体系, 提供稳定、可靠的构建部署流程, 结合 AI Agent 提供运维排障、依赖项水位监测等自动化保障手段。
- ❖ 采用 Autobots→RedBuild Admin→K8S 三层解耦架构, 实现了可拓展的索引构建模块, 并引入 Ray 等原生 AI 框架, 支撑了 RAG 知识库索引构建等新兴场景。

成果

保障索引构建成功率 99.5% 不破线; 高保索引的高时效性产出成功率高于 99%; 支撑线上业务超过 100w 核服务和超过 3000 个索引。

在离线一体化调度引擎

针对独占资源池碎片化严重、人工开退机、无法支持 AI 负载的问题, 设计并落地了统一资源管理体系, 实现在线服务与 AI/离线任务统一调度。

- ❖ 重构资源池体系: 独占池 → 业务混部池 + 公共混部池 + 弹性池, 支持 CPU/GPU 异构资源统一管理。
- ❖ 构建策略驱动弹性调度引擎: 基于 CPU/GPU 水位与负载趋势, 实现自动扩缩容 + 潮汐调度 (削峰填谷)。
- ❖ 打通自动化交付流程: 计费 → 调度 → 自动开退机 (CA) → 交付。
- ❖ 平台侧引入 Ray, 支持 RAG 数据处理、向量索引构建 (Embedding / ANN)、搜索近线推理等 AI 场景。
- ❖ 实现跨时段资源复用 (白天在线服务 / 夜间 AI 任务), 提升整体资源利用率

成果

资源迁移 17Wc+ (节约 1.8Wc+), 弹性资源 5Wc+ (峰值节约 2Wc+); 支撑 350+ RAG 任务, 索引构建效率提升 10 倍, 夜间复用 500+GPU

推荐系统内部资源调度与服务发现系统

针对传统服务发现仅支持实例级路由的问题, 设计资源级调度模型, 调度多语言环境下的资源, 实现统一资源管理和服务发现体系。

- ❖ 基于 Zookeeper (后升级至 etcd) 构建服务发现体系, 客户端通过 watch 实现去中心化路由决策。
- ❖ 开发服务端资源加载与注册机制, 支持模型/索引等资源的版本化、分片化管理。
- ❖ 实现 SWRR、locality-aware 等负载均衡算法, 支持机器性能感知自动调权。
- ❖ 构建资源管理与发布系统, 支持灰度发布、分批执行、回滚等能力。
- ❖ 打通资源发布 → 路由生效链路, 实现资源与流量调度一致性。

成果

支撑推荐核心链路高并发流量分发，实现资源级灰度与精细化流量控制，显著提升发布稳定性

专业技能

- ✓ 精通资源调度、弹性扩缩容、资源维度路由设计；熟练使用 etcd/ZooKeeper、MQ、Ray 等中间件与框架。
- ✓ 具备服务全生命周期管理、灰度发布、自动扩缩容、资源利用率治理、CI/CD 工程化落地能力。
- ✓ 深耕搜推广引擎的管控架构，具备大型分布式系统架构设计、性能优化与线上问题排查经验。
- ✓ 英语能力：CET-4 / CET-6，可熟练阅读英文技术文档写作。