

陈子豪

电话：17824256927 | 邮箱：fibonacci_rabbit@foxmail.com
当前状态：在职，考虑机会 | 求职意向：训练平台开发工程师

专业技能

- 训练容错：熟悉 DLRouter，了解预训练、后训练容错框架的设计，了解 pytorch distributed、异步 ckpt
- 强化学习：熟悉 AReal，了解 Agentic RL 框架设计、megatron，了解 GRPO、OPD
- 集群相关：熟悉 kubeflow、kube-schedule，了解拓扑感知、gang 调度、GPU 的故障发现、故障隔离

工作经历

支付宝

杭州

训练 SRE 工程师 AI训练组

2025年05月 - 至今

负责蚂蚁内部大模型训练稳定性相关的能力建设

训练稳定性

- 训练稳定性：作为训练方向特种兵，参与公司内大模型预训练、后训练的稳定性值班；主要工作包括了：排查启动失败、训练中断、hang、降速等异常问题；开发训练洞察平台以及一系列 profiling 工具，辅助故障发现 & 加快值班过程中的问题定位
- ASystem 训练有效时长：负责 ASystem 强化学习平台的有效训练时长、训练稳定性，主要工作包括优化框架的故障发现、故障恢复耗时，对使用 ASystem 训练框架相关异常的问题排查，针对 RL 场景开发一系列告警、自动化故障诊断工具
- 诊断平台：参与基于 Agentic AI 构建的快慢检分层的诊断体系建设，主要工作包括了：实现通过工具编排实现秒级模式匹配的快检层 & 基于 ReAct Agent 自主搜证承接快检失败 case 的慢检层；整理 Agent 必要的前置知识以及实现诊断经验的自沉淀

百度

北京

训练平台工程师 调度技术研发组

2023年10月 - 2025年05月

负责百舸训练方向的开发维护工作，获得 2024 年部门最佳新人

训练容错

负责内外部百舸集群数千卡训练任务稳定性，包括故障感知定位、快速恢复、交付检查、值班运维等

- 诊断系统：从 0~1 开发设计维护了一套异常感知诊断的系统，综合训练任务的软硬件监控、资源使用情况、日志、状态心跳等信息结合 BCCL、算力检测、py-spy、pyperf 等工具，来实现对异常训练任务的故障定位、hang 感知、慢节点查找
- 故障恢复：基于原生 kubeflow、elastic-agent 实现多种故障恢复手段，联动诊断系统、volcano、checkpoint 对异常训练实现自动容错和快速恢复
- 交付运维：协助用户 POC 交付训练集群，包括集群环境检查、参数配置、协助用户跑通 demo；以及协助排查内外部训练异常原因 & 定位问题

训练平台

负责百舸训练训练平台开发维护，包括了训练任务管理、百舸控制台、内部故障诊断平台的开发维护

- 任务管理：针对内外部需求使用方式，对百舸控制台、kubeflow、volcano 等组建进行开发维护，包括了支持训练任务的抢占、调度器分卡、细化任务状态、时间线、终态任务资源的自动清理、手动终止任务、确保各实例镜像拉取速度一致等

- 百舸控制台：负责百舸训练平台，包括开发机 operator、模型工厂、serverless 平台、对外 openapi 等的开发维护，包括了针对用户需求的功能迭代、etcd2mysql、接口性能优化等能力
- 诊断平台：为了方便值班同学快速定位内外部训练故障，设计开发故障定位平台，包括自动记录失败时任务快照 & 根据快照规则，自动进行训练故障分析定位

小红书

上海

基础架构工程师 容器架构组

2020年10月 - 2023年10月

先后从事小红书 go 语言中间件、注册中心、调度体系相关的开发维护

调度

- 负责调度体系的开发设计维护，基于 k8s 原生调度器、volcano、二次调度器、资源视图、virtual-kubelet、cluster-autoscaler 等，提高集群资源分配率、服务稳定性
- 针对业务场景，开发维护一系列原生调度器、二次调度器、volcano 的插件，包括统一调度、cpu 编排、负载调度、原地调度、资源预留、热点驱逐等
- 为提高资源分配率，减少集群资源碎片，开发维护了基于二次调度器实现资源碎片整理、基于 virtual-kubelet 和资源视图的空闲资源管理、基于 cluster-autoscaler 的空闲节点管理

注册中心

- 为替换公司原基于 consul 的注册中心，开发维护了基于 k8s 的服务注册和 eds 的路由表下发上线至今无 P3 以上 RCA
- 针对容器服务，开发维护基于 k8s 的服务注册 operator、webhook，实现了服务注册对业务逻辑无侵入；针对虚拟机服务，基于 consul 进行二次开发，使无需改变原注册方式的情况下接入注册中心
- 基于 istio pilot-discovery 和自研 discovery-proxy，为各语言 sdk 和 envoy 下发 eds 路由表，实现了推拉结合的服务发现模式 && 实例变更的 ms 级下发
- 开发维护流量管理平台，用于东西向流量调度，包括异常节点摘流、手动切流、动态调权等
- 开发设计注册中心的主备体系，实现异常情况下主备秒级切换，以及主备切换用户无感知

Golang 中间件（实习）

- 开发维护基于 fbthrift 的 rpc 框架，支持众多的服务治理特性；自研微服务容错框架、和基于 EDS 的服务发现中间件

滴滴

北京

服务中间件实习生 运维部

2019年10月 - 2020年08月

参与滴滴服务治理体系的开发维护

- 开发维护内部 go 语言 rpc 框架和服务发现 sdk，优化了连接池、负载均衡、出错重试、健康检查等能力
- 编写一系列 bash 脚本运维 etcd 集群，实现自动备份、故障恢复

教育经历

沈阳师范大学

沈阳

软件工程 本科 软件学院

2017年09月 - 2021年06月

- 专业排名前 5%，多次获得学习奖学金

其他

- **兴趣爱好**：折腾各种 linux 桌面发行版，骑动感单车，游泳