

陈宇

男 | 29岁 | 13777808792 | 2459231463@qq.com

4年工作经验 | 期望薪资：40-60K



个人优势

有丰富的爬虫对抗经验和行业解决方案；能做js逆向的爬虫架构，有0到1的搭建爬虫生态经验，有带爬虫团队经验。对爬虫流程和业务分离有一定认知；以数据赋能AI技术与广泛核心业务；陪伴AI行业数据需求发展从GPT问世至今；对完整的爬虫生态系统有认知，参与负责过构建爬虫管理平台化，多平台的持续全量增量爬取，服务器设备账号代理接码平台等资源管理，爬虫脚本框架模版，手机设备模拟器等工作

对逆向方面常见滑块、js混淆、vmp、常见加密算法、控制流、浏览器指纹、其他常见反爬策略和风控手段有解决经验，对加密和滑块有较丰富的研究和解决方案。

熟悉 aiohttp 的协程异步并发爬取和开发，做过常见网站的大规模爬取，对常见平台 Scrapy、selenium、DrissionPage框架熟悉。掌握爬虫任务调度apscheduler 定时任务框架，flask、fastapi开发接口，部署redash 和 crawlab 等管理平台也自己做过扩展开发配合jenkin实现ci/cd流程

具备操作Docker、数据库（如 MySQL、MongoDB 和 Redis）以及数据清洗（如 Pandas 和 NumPy）方面的经验

工作经历

上海米哈游天命科技有限公司 资深爬虫工程师 2024.09-至今

内容：

为集团所有游戏及平台提供全模态数据支持，核心服务AI训练与舆情业务。初期建设并完善舆情、竞品及创作者爬虫体系，后期转向AI大模型训练，全面负责大音视频/文本管线多模态数据支持，功课高难度平台数据资源获取，突破反爬、风控、协调资源并探索行业方案行业解决方案。同时带领实习生推进团队建设与技术落地。

业绩：

音视频：几百万小时

教育和网课视频：几十万小时；电影/电视剧/短剧：百万小时；音乐：140w首中文高质量/520w首全语言；

知识类：大约20亿token

新闻类：千万级（头条、微博、bbc\cnn。。）；文章类：千万级（微信公众号、虎扑、游研社、马蜂窝。。）

书籍：百万本（聚合源wxds，包含付费小说和数据）；小说：百万本（聚合源，包含付费小说和数据）

对话类：8亿数据

社媒/论坛问答6亿（知乎，虎扑，贴吧，豆瓣、小黑盒）；各类评论2亿（微博评论、知乎评论、网易云音乐评论。。。）

直播录制10w直播间录制3个月左右，多平台；直播弹幕采集；社媒平台持续增量抓取；xhs攻克和抓取；

累计产出亿级高质量问答、百亿文本、百万小时多模态语料，直接赋能模型的pre-train和mid-train,提高模型综合能力；

上海哈啰普惠科技有限公司 2024.04-2024.06

负责web难点攻克；app爬取和业务代码维护；

浙江吉利控股集团有限公司 吉利研究院技术规划中心AI大模型团队 爬虫负责人 2023.07-2024.04

内容：

带领爬虫团队，负责爬虫的持续维护和部署，包括环境的搭建和管理平台的配置。为研究中心AIGC及其它团队提供全方位数据支持。主导搭建爬虫管理平台，实现分布式部署与完整开发生态，负责大模型所需数据集（书籍、论文、题库、车辆舆情等全量和增

量）的逆向和爬取，有效应对海量数据性能、验证码、IP封禁及反爬机制等风控挑战。根据业务需求制定采集策略，探索行业内的方案和数据源，对接供应渠道，针对不同网站不同需求持续优化增量爬取与维护部署，确保数据合规稳定获取。

业绩:

负责大模型相关的网络数据的采集，从知乎(jsvmp,x96,v3老接口)等社区内容爬取、马蜂窝（jsl），驴妈妈，去哪儿，文献虫(文字点选)、知网搜索、微信读书（异步混淆加密）、当当、豆瓣、豆瓣读书。
prompt爬虫、书籍文本清洗脚本、车辆评论死链判断脚本、huggingface爬虫
为rag赋能，做了头条新闻，百度搜索接口，bing三个搜索引擎的搜索聚合服务
40w网络书籍 20w标准格式书籍（epub，mobi等）、当当全部书籍sku60w，马蜂窝全部旅游景点、详情，路线。知乎社区文章问答，知网学术论文pdf5.5 万方4w，论文摘要200w、古诗词诗歌网总计200多万

上海一嗨汽车租赁有限公司 爬虫工程师，爬虫组长 2022.02-2023.06

内容:

在开发半年后作为爬虫组技术负责人带领团队，做了爬虫的开发和维护，技术评估和可行性分析，基础应用搭建和集群管理的探索。参与一些公司探索类项目，做一些爬虫通用工具。调度资源，分配任务，给技术部提供数据支持，给业务部门提供自动化办公脚本。尝试在windows环境下统一管理爬虫（因为很多gov或u盾项目需要图形界面）。研究并攻克了App和小程序的逆向需求。将原本java写的在xxl-job上跑的爬虫代码使用python重构和维护；将部分selenium自动化脚本使用js逆向重新开发；提高了稳定性，降低了维护成本，解决了较为复杂的遗留需求和新的难度需求。
用crawlab做集群和管理。用机房的服务器搭建多节点的分布式爬虫管理系统（win虚拟机docker 跑一些需要图形化的爬虫）配合Jenkins做发布，让全类型的爬虫都可以跑；
研究了阿里云的faas开发，参与了saas项目进销存系统的开发（python开发），负责商品管理和出入库那块，到盘库为止。开发了一些爬虫通用工具，实现了基础的爬虫模板（使用apscheduler+pymysql+requests封装），集成了企微、邮件、微信消息通知（微服务化），aes加解密，日志，apollo获取配置等常用工具，异步批量的saveData等工具。使得多种复杂业务都使用模板项目。并维护了Tornado消息中心项目 期间做了一个n个城市的牌照指标自动化办公爬虫（模拟登录和数字验证码）大华捷通支付平台交易记录自动化办公爬虫（selenium过极验），五个二手车平台的数据爬虫，然后搭建了redash方便查看和展示入库数据。爬取途虎养车app所有车型车系和保养手册（搭建的小黄鸟的逆向环境root手机，jadx），爬取北京停车小程序（取巧过滑块，逆向验证码,搭建小程序逆向环境fiddler）。工商银行（封装ddxoft虚拟键盘过U盾）。交管平台，30个U盾实现分布式爬取(css逆向提高爬取效率)配合U盾服务器，同时开发了flask api接口（也封装了模板，将之前的模板升级结合线程池，，异步请求，rest的上下文管理装饰器，定时任务，swagger,restX，还实现了一个轻量数据库连接池helper支持批量入库上传了pypi，以及丰富的通知和爬虫工具类），逆向神州租车app。及其他较多数据处理类任务，维护java爬虫，用python和java分别写了一系列接口项目，以及今年写了一个chatGPTai聊天室给公司业务部门用，多账户调度，多用户聊天历史，阻塞队列，访问频率aop限流器，实现了上下文管理。

业绩:

组建起了爬虫团队，和队友们建设了爬虫生态、基础应用搭建和研发性项目。搭建了爬虫开发流程（SOP），模版和基础应用，数据采集开发和平台搭建.制定爬虫开发流程和管理方案；

开发基础应用和爬虫种子项目，提供爬虫模板，开发爬虫数据 api，集成爬虫定时任务等功能，使用Flask开发了一个集成爬虫和RESTful风格接口项目的框架模板，提升了项目的可扩展性和可维护性。搭建和部署了管理平台，迁移了旧爬虫，实现了集群管理，规范了上线和开发流程，提升了系统的稳定性和性能。

实现自动化办公，分为获取和提供数据的。集中管理了U盾的，解决如违章信息，银行流水，租赁合同录入取消续租和车辆备案功能，停车费获取，支付录入，牌照指标获取等。其他一些网站 如黑猫投诉，自动爬取投诉信息自动回复友好提示。疫情信息获取实现消息推送等。开发了基于gpt聊天服务集成到了微信机器人、做了税务网站开发票的自动化，方便公司业务部门使用

项目经历

内容:

某中文互联网高质量问答社区，过去全量数据和过往一年增量数据的持续爬取；解决知乎强风控访客参数zseck，翻页参数x81绕过，x96还原；实现与行业内多家（舆情公司、数据供应商等）量级对比更高更完整的获取；持续获取问答，增量和持续刷新反馈信号，完整获得评论以及子评论；有一整套完整的方案；从搜索；话题；问题；多维度构建；实现全接口可通；有独立的养号逻辑；

业绩:

总计4亿回答；3000w问题，800w文章；评论可全部获取，可定期回采反馈信号；对于大模型的Pre-training和SFT训练有极高价值，提升模型的对话感；

音视频爬虫

内容:

音乐：网易云音乐全部中文歌曲，spotify歌曲
播客：三联周刊，小宇宙，懒人听书，喜马拉雅
教育视频：赶考、网易云课堂、网易公开课、中国大学MOOC、超新尔雅、智慧树等
短剧\电影\电视剧：mxvod、msvod、imdb、tmdb
同时持续录制dy，ks，tk，ytb总计10w个直播间。总计1600w小时直播数据（可根据是否有人上麦做录制逻辑。同时获取指定直播间的弹幕）；
某包超自然音色语言蒸馏录制（2023-2024年项目）

业绩:

总计交付140w小时中文优质；非dj 非轻音乐纯音乐。非素人翻唱、非背景音乐，非播客，一定有中文的优质纯中文歌曲 Audio数据；200w小时电影电视剧短剧vedio数据；40w小时网课教育视频数据。20w小时博客数据；

推特和其他社媒、新闻资讯类爬虫

舆情和创作者业务的推特平台爬取;对指定的用户、指定的搜索词进行持续监控;并定期回溯刷新帖子的转评赞等反馈信号;解决推特的x-client-transaction-id生成问题；实现搜索、评论、用户发帖的接口逆向；问答产出日百万级别的指定内容爬取；

其他各类新闻网站和海内外平台，facebook、reddit、xhs、抖音指数，百度指数，微信指数，bing新闻资讯，微博热搜、话题，百度新闻我们做了非常多的尝试;可以做到对指定用户获得发帖内容和评论；实现业务和爬虫分离；爬虫单独对功能负责，业务侧维护创作者库，舆情关键词，情感分析模型，直播监控接口等;做定期持续爬取；

微信读书书籍类爬虫项目

微信读书爬虫系统（微信读书、豆瓣读书、国家图书馆、畅想之星图书馆、qq 阅读机构版、番茄、起点、晋江）
解决如无限debug绕过，异步js调试、字体加密、编码还原，微信读书ps、pc值的逆向、skey的登录态保持，书籍详情的逆向还原；
因为大模型训练需要用大量有价值的书籍（网络小说、传统文学、数学公式代码、工具类书）、百度网盘直接找的开源盗版书籍文件质量低下、清洗完只有几万本能用的，市面上较好的有微信读书、豆瓣阅读两个平台，对平台内容性质等做调研后 决定采集微信读书的图书（以购买会员账号包月的方式，合法采集），经过破解还原了每本书的请求方式和加密的参数、能够解析返回的编码为正常的文本且保留公式格式。最终采集了以微信读书为代表200w本书籍的数据，用于赋能大模型的训练。

论文文献社区爬虫

因为大模型的训练需要大量学术论文，知网直接下载是很贵的，然后万方大部分镜像站是期刊（价值较低而且格式乱），我通过对行业里渠道的联系获得知网数据源，进行爬取。解析了搜索下载逻辑和论文参数，解决了加密，文字点选，账号ip 频率风控问题 最终实现

知网学术论文pdf15.5w 万方18w，论文摘要300w；百度百科 1000多w 使用分词；
题库爬虫考试酷考试宝考试猿其他各类题库2000w；爬取谣言新闻爬取，招标中标爬虫，搭建爬虫基础架构

滑块验证码相关

2023.01-至今

内容：
逆向过程中遇到的：极验滑块、数美滑块、易盾滑块、百度旋转滑块，字节滑块，数美风控；三国闲话自研滑块、知网文字点选、腾讯云天御文字点选；这些滑块反爬应用极其广泛，知乎，知网，头条，抖音，百度，账号交易，网易系列等网站都会用到

业绩：
极验是扣w值是aes加密
腾讯滑块是魔改的TEA加密
数美是动态的参数轨迹和环境取了一些指纹des
易盾是一个webpack，补环境得出
百度旋转是vmp，训练使用resnet50效果有个6-70成果率
字节滑块也是vmp，但是加密在外面，主要扣操作流程是对各种环境base64出来切的k,v做的aes
文字点选是只要坐标就行，用ddddocr得到文字坐标切出来，用hanzisimier这个字体识别模型（部首+字形），识别相似度

游戏逆向、APP逆向和小程序逆向

逆向工程师

2024.01-至今

三国杀游戏逆向、三国咸话app、游民星空app、网易大神app逆向还原
qq授权登录参数流程：掌上英雄联盟、瓦罗兰特拳头登录接口5秒盾解决、

通过JS逆向、AST、动态调试，APP反编译、HOOK插桩、签名算法逆向分析等技术突破7881、游民星空、掌上英雄联盟、网易大神等平台设置的反爬虫策略如用户代理检测、IP封禁、限制访问频率、数据签名保护等，编写相应算法代码生成对应参数，整合成接口形式提供使用

tuhu养车 app 的全部车辆和保养手册（15w数据）神州租车的租车点车辆价格信息北京停车费小程序，高德特价车，美团打车等、三国闲话 滑块登录 用户信息，豆包超自然语音生成

其他社媒-论坛类爬虫

2022.02-至今

常见二手车网站(gz,rrc,yx,dcd,二手车之家)大量采集，单站日数据超10w,异步架构，分别解决逆向字体加密，滑动模块等反爬，过定期跳滑块，并对一个数据量大的爬虫做了异步协程，同时用了代理池 实现了高并发的稳定爬取

马蜂窝全部旅游景点、详情，路线，爬取国内全部7万都旅游景点景点数据做小模型的路途规划、景点推荐 马蜂窝全量爬虫（2800个城市，7万多景点，中国全部的景点和介绍、以及全部旅游线路和介绍，训练模型用于对话系统的旅游规划和景点推荐）后续补充了驴妈妈，去哪儿的景点数据

教育经历

浙江万里学院

本科

数据科学与大数据技术

2020-2022

主修：python面向对象编程，数据结构与算法，数据采集，数据可视化，mysql，H5web开发以及大数据开发相关技术。
主要做过几个小程序 一些web的前端设计，爬虫，数据看板，等项目
在校期间积极参与竞赛和实践，做一些创业创新项目、拿过创新创业奖金。
担任过学习委员 参与过校内创业创新 职业生涯规划等比赛

19年的 大数据应用技术 省赛及国赛拿下全国第一 有被赛事官方和学校当地采访报道 整个大学参加acm工作室参加过acm省赛
有蓝鸥培训机构python课程的毕业证书， pat计算机等级证书 b级
有一定的爬虫以及web开发的项目经验；做过微信公众号项目游戏自媒体、校园论坛
优秀毕业生 国家励志奖学金获得者

社交主页

<https://blog.csdn.net/paycho>