

马里昂

大模型数据工程师

13031066085 | maliang_ai@163.com | 北京
武汉工程大学 | 计算机科学与技术 | 本科 | 2010 - 2014

个人简介

12年数据工程经验，3年AI模型数据工程经验，9年大数据平台与服务经验。构建PB级多模态数据Pipeline，日处理Agent轨迹10亿条，训练数据准备周期从2周缩至3天，数据交付时效从T+7缩至T+1。

核心技能

大模型数据工程：LLM/VLM训练数据准备、SFT数据构建、RLHF数据工程、Agent轨迹数据处理、Data-centric AI方法论
多模态数据算子：文本分类、图像质量评估、视频内容理解、OCR/ASR、音色属性打标、图文对齐、图片去重（感知哈希+特征向量）、视频抽帧、跨模态对齐
数据处理框架：Spark、Dorado、Hive、Kafka
数据质量与合规：LLM-based质量评估、大规模去重、PII去标识、数据漂移监控、启发式规则引擎
编程语言：Python、Go、SQL

工作经历

字节跳动 | AI数据工程师 | 剪映CapCut业务

2023.12 - 至今

负责剪映、CapCut、即梦、醒图等AIGC产品的大模型训练数据体系建设，覆盖预训练+SFT+RLHF全阶段，打造“数据-模型-业务”迭代飞轮。

字节跳动 | 大数据工程师 | 抖音业务

2020.08 - 2023.12

负责抖音大数据应用与中台数据服务建设。B端：流量/交易/履约数据洞察体系、种草价值度量；C端：POI信息服务与质量分服务。参与TikTok电商/直播海外数据服务与TTP/GCP部署。中台服务avg QPS 200w+，max QPS 300w+，零线上事故。

2017.08 - 2020.08 瓜子二手车数据平台团队，BI/OLAP数据平台建设

2014.07 - 2017.08 看车科技研发部，数据营销/CRM系统建设

项目经历

项目一：端到端多模态训练数据供给体系

基于Data-centric AI理念，为即梦、剪映、醒图等AIGC产品构建从数据采集到训练交付的端到端数据供给体系，通过优化训练数据驱动模型效果迭代。

一、多模态数据矩阵与预训练数据建设

- 设计开源+域外+域内三层差异化数据供给架构，按pretrain/SFT/RL阶段匹配不同数据源与质量标准，数据规模达E级
- 域外预训练语料：整合Instagram/Amazon/YouTube/TikTok千万级图片与视频数据，构建多模态预训练语料库
- V2T视频反解Pipeline：将视频分解为ASR转录、OCR文本、音色属性、画面结构等多模态要素，处理千万级视频，为编导模型提供预训练语料
- 设计草稿→成片结构化训练Pair对收集链路，累计回收百万级Pair对，覆盖pretrain（原始素材解析）/SFT（高质量修改子集）/RL（模型输出vs用户修改Diff）全阶段
- 建设大规模去重基础设施，完成千万级视频文案去重（去除10%重复），构建相似度检索API支持SFT去重与Bad Case溯源

二、Agent轨迹数据链路 with RLHF数据工程

- 构建5条产品线的Agent数据链路，将用户交互行为转化为SFT/RLHF训练数据，日处理轨迹超10亿条
- 设计轨迹采集方案：多轮对话轨迹与业务埋点Join关联、意图粒度聚合、会话级去重
- LLM+规则双通道清洗：完成无效对话过滤、低质生成剔除、跨模态对齐校验，可用率从30%提升至75%
- 数据合规体系：国家地区白名单过滤、PII自动去标识化，支持海外轨迹复用，合规耗时降低60%

成果

- 支持5个AIGC产品模型迭代，覆盖DAU超亿级用户数据
- 数据交付时效T+7→T+1，模型迭代效率提升85%
- 训练数据准备周期2周→3天
- 编导模型草稿数据累计回收22w+条，支撑3条模型线pretrain与SFT数据供给

项目二：多模态数据算子库与质量评估体系

基于训练数据供给体系，构建可复用的多模态数据算子库与数据质量评估体系，对应Data-centric AI的Data Processing与Data Understanding环节。

一、多模态数据算子库与流水线引擎

- 设计并实现多模态数据算子库，封装图像质量评估、视频内容理解、OCR/ASR解析、音色属性打标、图文对齐度评估等通用处理逻辑
- 基于Dorado+Spark构建配置化流水线引擎，支持算子快速编排，数据加工流程标准化
- 图像去重算子（感知哈希+特征向量）、视频抽帧算子（关键帧+均匀采样）、音频转写算子（Whisper）、跨模态对齐算子
- 风格化SFT自动化工具：prompt+视频→文本的SFT数据生成工具链，支持数据增强与1-2w量级SFT数据快速产出
- 敏感内容识别与安全过滤：ASR违规过滤，敏感数据可视化查询平台

二、数据质量评估与模型效果归因

- 建设数据质量评估体系：基于LLM和启发式规则的数据质量打分，覆盖语义质量、模态一致性、信息密度
- 意图挖掘：Agent对话意图识别与聚类，识别50+核心意图，指导SFT数据配比优化
- 模型效果归因：打通线上模型链路，按意图场景监控模型效果变化，建立数据→效果的归因分析
- 效果链路工程化：数据漂移监控与Bad Case排查

三、大模型评测平台

- 生图评测平台：自动跑图、多模型多版本对比打分、评测报告自动产出，打通10+竞品对比
- 生视频评测平台：多人多轮评测管理与众包人效管理
- 评测能力支撑即梦生图/生视频两条产品线迭代决策

成果

- 算子库沉淀20+算子，覆盖80%的AIGC数据处理场景，流水线引擎使人效提升5倍
- 图片质量评估准确率92%，视频内容理解准确率85%
- 数据交付周期1个月→1周
- 50+核心意图识别，支撑SFT数据配比与产品迭代决策