

黄雨婷

联系电话: 13310111458

电子邮箱: 1531027448@qq.com



技能/技术栈

编程语言: Python (精通)、SQL、Shell、R

算法/模型: PyTorch、Transformer 架构、LLM SFT、Embedding、Prompt Engineering

数据工程: 大模型训练数据全流程处理、Pipeline 自动化、数据合成与增强、弱监督/无监督数据处理、增量数据更新

AI 工具链: Claude Code、Hadoop、Linux

教育背景

上海外国语大学 | 国际金融贸易学院 | 金融硕士

2022.09-2024.06

- 平均绩点: 3.79/4 (排名 19/122) 主修课程: 公司金融(90)、金融数据挖掘与 R 语言(92)、金融科技(91)、金融理论与政策(92)

中国计量大学 | 理学院 | 理学学士, 数学与应用数学

2018.09-2022.06

- 加权平均分: 83.33; 主修课程: 概率论(95)、深度学习(93)、数据库技术 SQL(86)、JAVA(91)、运筹学(91)、Matlab(90)

工作经历

科大讯飞 - 核心研发平台-音频理解条线 | 数据研究

2024.06-至今

大模型训练数据 Pipeline 建设 (核心在行项目)

- 全链路 Pipeline 主导搭建:** 从 0 构建"寻源-采集-解析-处理-实验-分析"完整数据生产链路, 覆盖 68 语种的多语种训练数据。具备 TB 级大模型训练数据的工程化交付能力; 运用 Claude Code 对文本、音频等多种异构数据形式完成统一处理转化与接口集成, 沉淀可复用数据算子, 提升数据策略迭代效率
- 自动化框架建设:** 主导构建自动化数据清洗框架, 针对音频解码引擎开发多线程优化与 GPU 资源调度脚本, 实现多任务并行处理, 数据生产吞吐效率提升 70%;
- 数据范式扩展:** Pipeline 从初期有监督数据处理逐步扩展至弱监督与无监督数据场景, 设计适配不同标签密度的处理策略, 拓宽预训练数据来源, 增强模型对低资源语种的泛化能力
- 模型评测反向迭代:** 参与 SFT 训练数据供给, 设计多组对比实验 (不同数据配比/来源/清洗策略), 结合模型识别效果评测反向迭代数据生产 Pipeline, 提升数据生产与模型能力提升的匹配度; 建立质量评估指标体系, 持续监控数据分布与异常波动, 支撑多语种 ASR 引擎训练闭环

业务训练数据合成与挖掘

- 数据合成与多样性建设:** 面向低资源语种、场景设计多维文本生成方案 (仿真、朗读、关键词混淆等), 通过 LLM 合成构建 1000 万+句 高质量对话数据集; 构建 3.5 万+高质量领域实体词库, 3 个月内交付 5000+低频词汇、40 万+条领域文本, 支撑场景化数据标签体系建设
- 数据质量管控:** 设计混合筛选算法 (LLM 质检+规则过滤), 数据合格率稳定在 90%以上, 质检效率提升 75%; 通过错误归因与长尾劣质语料拦截机制, 持续优化数据质量, 为多个语种识别引擎提供高质量、多样性数据供给

实习经历

上海哔哩哔哩科技有限公司 - 人工智能平台部 | 算法运营 (CV 方向)

2023.06-2023.09

- 数据运营:** 负责人工智能机器审核算法和产品的评估与策略标训, 通过数据驱动产品迭代, 模型性能平均提升 80%, 交付效率提升 100%, 体现数据敏感度与分析能力。
- 项目管理:** 运用 TAPD 建立评估指标体系, 完善平台数据工作流程, 提升整体协作效率。

语言

语言: CET-6; 雅思; 小语种数据处理经验