



牛人已开启手机号隐私保护

您可使用BOSS直聘APP扫描二维码联系Ta

fc250a9cafec1db1HB-09%9ElpUyoy9UfKaWOGmmvLTmhfM3g~~

南江涛

男 | 年龄: 33岁 | 13716584420@163.com

10年工作经验 | 求职意向: 数据架构师 | 期望城市: 北京



个人优势

- 一、领导过3-5人的数据团队，海量数据采集、预处理经验。
- 二、主导数据平台：全栈研发经验（企业级，已上线投入使用）。
- 三、喜爱技术研究、乐于分享、责任心强、注重技术氛围及团队协作。

工作经历

北京面壁智能科技有限责任公司 数据开发 2025.08-至今

- 1. 预训练多模态数据处理（B站、Youtube等音视频）。
- 2. 海外学术期刊图文数据处理。
- 3. Atlas 系列数据平台全栈开发。以 Atlas 为底座，AtlasHub 提供数据消费窗口，AtlasX 提供 Agent 命令行入口，三层共同构成多模态数据生产闭环。

北京美图之家科技有限公司 数据治理 2024.12-2025.07

- 1.负责公司大模型数据研发,构建高效的流式data-pipeline
- 2.影像Agent工程研发，基于LangChain、LangGraph 框架，使用ReAct推理模式，开发图像、视频Agent。研发MCP相关功能。

北京面壁智能科技有限责任公司 数据开发 2023.07-2024.12

内容:

- 1、PB级图文、音视频多模态数据获取、清洗、转换。
- 2、数据预处理data-pipeline研发。
- 3、智能采集平台研发。

业绩:

- 1.完成交付PB量级各类型数据。
- 2.针对图文数据、音视频数据，开发预处理data-pipeline。
- 3.研发数采平台及任务实时日志统计、报警系统。

上海储能领跑者联盟 数据架构师 2022.10-2023.05

内容:

创业性质

- 1、基于阿里云，kubernetes+gitlab，CI/CD 体系搭建
- 2、基于能源专利局数据、国内能源行业数据，能源知识图谱开发。

业绩:

- 1.搭建完成初创团队企业级敏捷开发流程。
- 2.交付能源行业产业地图。

上海联恩商钥互联网科技有限公司

资深数据开发工程师

2021.08-2022.09

- 1、药监局、小红书、淘宝预售、知乎数据获取及清洗、词云开发。
- 2、数据获取架构方案设计及开发实施

北京吧咭科技有限公司

高级数据开发工程师

2019.07-2021.06

- 1、负责 baca 新闻社区平台的数据ETL系统、后台管理系统。
- 2、负责电商 flashgo 平台数据比价系统，数据来源为 shopee、lazada。
- 3、负责电商 mokaya 平台快递、物流、优惠券相关业务。

北京新尚品科技发展有限公司

研发主管

2016.08-2019.06

- 1.开发搭建公司数据微服务系统，根据业务模块划分为：数采服务、网页监测报警服务、数据实时更新服务、后台管理服务。
- 2.自动下单功能的开发。
- 3.基于用户行为，进行数据分析。

项目经历

Atlas 平台项目

全栈研发

2026.02-至今

内容:

- Atlas 全模态数据平台：面向公司模型训练数据生产的一站式平台，覆盖 19+ 内容源（B 站 / 抖音 / 小红书 / 微博 / YouTube / TikTok / X / Reddit / HuggingFace 等），承担「采集 → 去重 → 预处理 → 特征化 → 入库 → 检索」全链路。个人独立主导从架构设计到落地上线，通过vibe coding 完成 30+ 微服务、100+ Skill、双区集群部署，覆盖后端 / 前端 / Agent / 数据 / DevOps 全栈。
- AtlasHub 数据集门户：对标 HuggingFace Datasets 的内部数据资产门户，把 Atlas 拥有的数据按平台维度做卡片化展示 + 样本预览 + 后台管理，帮助算法团队「自助选数据」。个人独立全栈交付：产品方案、UI 设计、前端组件、后端、Dockerfile、K8s yaml 全包，通过 Vibe Coding 高效推进。
- AtlasX — Terminal-Native Agent：把 Atlas 全链路「登录 → 规划 → 执行 → 产出」用命令行交互形态呈现的轻量入口，给用户 Terminal风格 的 CLI 体验。
- 技术栈：FastAPI · React 18 + TypeScript + Ant Design Pro · LangGraph · MongoDB Replica Set / Redis / RabbitMQ / Kafka · Flink · Milvus · OpenSearch · OBS · 双集群（北京 + 香港）· K8s。

业绩:

● 架构与后端

微服务拆分与落地，采用「控制面（gateway / demand / task）+ 数据面（collector / dedup / preprocess / feature / search / sync）」分层架构，通过gateway统一实现JWT鉴权、CSP策略及WebSocket代理。

实现跨集群K8s调度，支持in-cluster与kubecfg双模client，HK Job通过公网LB回调BJ gateway，内部回调通过AUTH_WHITELIST白名单控制。

● 数据平台 / 去重索引

设计流批一体架构，Kafka作为主总线承载数据事件流（raw.ingested / raw.valid / preprocess.dispatch / feature.ready / quality.alert），RabbitMQ保留任务控制流，Flink Job实现实时清洗、质量规则与乱序处理。

自研atlas-dedup-registry全局去重索引（3000w+ (platform, unique_id)记录），基于MongoDB Change Stream推模型 + batch（200条/500ms）+ resume token持久化 + 全量backfill兜底，对外部skill镜像零侵入。

实现多模态检索：feature-service使用CLIP/多模态embedding写入Milvus + OpenSearch，search-service实现关键词召回 + 向量召回 + 过滤排序；lineage-service聚合Flink指标 + 元数据，展示完整数据血缘拓扑。

● skill 能力落地

逆向各内容平台，合法合规实现最小单元的功能模块，以yaml的形式提供出skill能力，供Agent 智能编排使用，并灵活组建最优DAG任务，满足任务需求。

● Agent / LLM 编排

自研agent-service LLM编排引擎（基于LangGraph），实现自然语言→意图识别→Skill选择→DAG编排→人工确认→执行的全链路流程，支持SSE流式推送推理过程。

设计声明式Skill Manifest + Templates体系（覆盖19平台100+ skill），通过manifest.yaml声明skill相关功能，LLM从模板池选最优DAG，显著降低幻觉率。

实现Human-in-the-loop机制：LLM生成DAG后用户可在UI拖拽修改并确认下发，试跑120s超时自动fallback，防止幻觉导致K8s Job雪崩。

通过线程池 + 队列实现overload保护（50 worker / 100 queue），超阈值自动503拒绝，保障LLM推理不拖垮主服务。

● 前端 / 平台账号

交付console-web管理后台（React 18 + Ant Design Pro），包含数据需求、任务监控、智能编排、数据浏览、链路拓扑、浏览器noVNC嵌入、ASR\数据打标等多个功能模块。

● 双集群+GPU 集群调度

通过任务规模，平台自动扩缩容，完成任务需求。GPU 任务，可自动切换资源充足的节点执行各处理算子。

美图AI/Agent

高级研发

2024.12-2025.07

一、奇想大模型：

- 1.分级治理海量多模态数据,高效完成数据打标、数据切帧、数据整合、数据同步等任务
- 2.基于flink+kafka+hive,搭建PB级图片、视频数据pipeline,支持复杂的业务需求,灵活配比多种数据
- 3.搭建airflow平台,开发相关数据任务
-

二、美图智能体RoboNeo：

- 1.基于LangGraph,开发美图Agent.开发MCP server/client
- 2.基于Qwen2.5VL、deepseek-chat、Seedream混合模型,使用COT,ReAct技术,搭建精准、高效的Prompt工程
- 3.调研Lovart等设计领域相关Agent竞品,分析其执行流程

cpm系列模型数据

数据研发

2023.07-2024.12

内容：

- 1. 结合大模型数据需求场景，开发数据采集-预处理平台，目标自动化交付预训练数据集。

核心功能点：

- 使用spring-boot3、vue3，开发数据平台，实现权限管控、任务配置化，结合kubernetes-gitlab-agent实现部署自动化（CI/CD），各系统模块间，通过rabbitMQ实现解耦。
 - 通过搭建EFK日志系统，完成数据任务全链路监控，使用grafana图表展示。
 - 基于大数据治理流程，针对不同数据集，开发python\spark清洗脚本。
- 2.多模态数据ETL
- 开发完成百科类数据的ETL，如百度百科、维基百科、萌娘百科等。
 - 基于TB级新闻、小说等图文数据，搭建数据ETL流程。
 - 开发完成PB级音视频数据的采集、分类、切分、转换流程。

业绩：

- 两月内交付，TB量级的纯文本预训练数据
- 一月内交付，1B多模态图文数据
- 一月内交付，PB级音视频数据
- 完成data-pipeline的工程能力建设

- 完成国内外kubernetes开发集群的搭建、维护
- 设计PB级数据底层存储，打通数据同步链路：hdfs-s3-juicefs

DevOps体系搭建、能源知识图谱数据运维负责人2022.10-2023.05

一、结合当下云原生技术，使用阿里云，基于 gitlab ，集成 kubernetes1.25.4 ，搭建企业级的 devops 体系，3主多从，按需扩充节点。

- 集群内部网络使用 flannel ，ceph 分布式存储系统。
- 搭建 EFK 日志体系，使用 fluentd 收集各服务的日志，kibana 制作可视化报表。
- 搭建 prometheus+grafana ，监控各 pod 的运行状态。
- 使用 helm 安装一系列服务组件：gitlab-runner、gitlab-kube-agent、redis、mysql、mongodb、minio、kafka、rabbitmq等。
- 按 namespace 分配不同业务线，按 node-label 区分不同开发环境，部署相应服务，使用灰度发布。

二、能源知识图谱

- 一月内获取欧洲能源专利全站数据，使用到的技术：js逆向、数采架构设计、oss存储。
- 同步oss数据到hdfs，使用阿里emr，编写spark代码，对专利数据进行ner\nor处理，抽取数据引用关系，使用Neo4j存储能源各企业、人物关系，完成能源行业地图。

Thelian-Crawl负责人2021.08-2022.09

内容：

一、完成以下平台数据：

- CFDA化妆品备案数据获取（全量|增量），使用到的技术：js逆向分析，破解无限debugger，解除IP封禁，hook瑞数5代加密，点选验证码破解；
- 小红书数据获取，完成的功能有：手机号登陆生成token，数美滑块验证码破解，请求搜索接口；使用到的技术：安卓逆向分析，jadx/gdb反编译，smail静态分析，使用ida配合frida/unidbg对so文件动态分析；
- 知乎数据获取，搜索数据接口，js逆向，算法还原；
- 淘宝活动日预售数据采集，使用到的技术：selenium模拟登录，js逆向，影刀rpa开发；
- 统一采集平台对接，数采架构设计，使用到的技术：scrapy-redis，apscheduler，flask，docker部署，puppeteer，rocketMQ，elasticsearch；
- 验证码接收app开发，android开发，已投入使用；

二、实时数据报表，采用存算分离的架构：

- 按日更新淘宝商家后台营销数据（商品，商铺，财务等），通过自研数据采集框架，配置化淘宝商家后台接口，获取每日数据。
- 自动化日更营销数据，将采集到的数据存入mongodb，通过mongo-connector同步数据到clickhouse。
- 使用dbt处理数据，导出csv文件。
- 使用pandas进一步处理csv文件，调用Power BI api，将数据可视化。

业绩：

正常按时交付，及时调整采集策略，满足数据需求。

日更报表可视化投入使用。

Baca社区、FlashGo电商、Mokaya物流高级数据研发2019.07-2021.06

内容：

公司以东南亚印尼市场为主，以新闻资讯平台 baca 为核心业务，老的电商平台有 flashgo ，新增电商平台 mokaya。

一、负责 baca 新闻社区平台的数采系统、后台管理系统。

- 1、资讯数据采集系统，使用 redis-scrapy 框架，以抓取 facebook、instagram、youtube 三大网站的图文、视频相关数据为主，存储为 mysql、es、azure-storage，代理为 scrapyhub 提供，linux 系统下，docker 部署。
- 2、google-app 数据采集，使用 node 开源库 googleplay-download 做解析，以 python 开发为主，redis 做任务调度，提取 google-app 相关数据，包括头图、视频、简介、开发者、地址、评价星级、评论等等相关内容，Azure-k8s 集群下，docker 部署。
- 3、社区后台系统，公司内部运营人员使用，使用 flask 框架开发，前端为 vue，前后端分离。功能模块包括内容管理、话题管理、google-app 管理、统计，功能业务简单介绍：抓取内容及用户发布内容的审核、上下线，评论相关的审核；内容关联话题及关键词、标签的管理；网站内容数据的发布、访问统计，分析数据的流向及热门话题，以此进一步优化内容板块。
- 4、UGC 鉴黄审核，使用 pytorch 基于预训练模型 ResNet-50 对图片进行鉴黄，针对视频，通过 ffmpeg 截取视频前后中三张图片，做鉴黄处理。

二、负责电商 flashgo 平台数据采集比价分析，mokaya 平台快递、物流业务

- 1、针对用户需求，采集 shopee、lazada 平台商品信息，并提供比价分析报表，定时更新 flashgo 商品数据。
- 2、采集货物快递信息，两种形式：物流合作商提供接口、网站获取的抓取接口，20 分钟更新一次并同步线上。
- 3、下单发货业务，对接 jne 物流合作商，打通线上下单发货到物流快递人员取货送货流程。

业绩：

baca 社区数据及后台稳定上线投入使用。

flashgo 电商数据及时更新。

mokaya 物流相关业务打通并完成开发任务投入使用。

尚品电商数据平台 研发主管

2016.08-2019.06

内容：

一、负责运营人员使用的电商数据采集系统，用于获取多种电商官网平台的商品数据。

框架为 spring cloud、spring boot，linux 环境下，java 配合 nodejs，包含爬虫服务、数据监测报警服务、数据实时更新服务、后台管理服务构成此分布式系统的生态；nginx 做负载均衡，consul 做注册中心、服务发现，服务间的调用使用 feign；系统内部，均为异步执行，业务上高内聚，服务间低耦合，以下为各服务简介：

1. 爬虫服务采取动静分离、多进程多线程的模式，配有多任务的处理及相应的破解反爬策略，服务为宽度抓取，对数据要求精准。基于 webmagic 的二次开发，java 配有 httpclient、jsoup、selenium 三种下载器，nodejs 配有 puppeteer 动态解析器，使用 xpath、css 解析页面元素，针对动静数据分开处理；使用线程池及进程池，并行抓取、提升性能；基于 redis 的调度器，及基于 mysql 的数据存储及清洗。支持 windows、linux 系统，高扩展性。

2. 数据监测报警服务，以 page digest 算法为核心，对目标网址链接进行抽样，实时监控网页变化，以节点、属性、文本为三大维度，判断网页的具体变化，随时可调整的监控灵敏度，针对变化的具体情况做报警处理，使用 redis 发布订阅模式异步处理报警信息，配合爬虫服务，数据实时更新服务使用。

3. 数据实时更新服务，针对已获取的数据，需要及时的进行更新，根据爬虫服务的爬取规则，区分动态静态数据，调取不同的解析服务，配合监测服务，以此来实时更新已有数据。动态解析，以 nodejs 提供的服务为主，为分布式部署，以 redis 做更新链接缓存，同时以 redis 发布订阅模式传递不同服务间的数据。

4. 后台管理服务，对爬虫服务、监测报警服务、数据更新服务做数据监控，以图表的形式展示各服务相关信息的变化，bootstrap 开发后台样式，spring security 做权限控制。

5. nodejs 为独立的动态解析服务，运用于动态页面的数据解析，以 puppeteer 为核心，使用事件驱动，异步执行，nodejs 集群

部署，分布式提供服务，支持百万级并发，爬虫服务、监测服务、实时更新服务皆有使用。

二、独立负责自动下单业务的开发，java 开发，使用 selenium、chromedriver 模拟人工下单，完成下单自动化，商品匹配准确。

三、基于用户订单数据，进行数据分析，提供商业决策：

- 1. 使用 sql ，针对用户订单数据进行数据清洗，缺失值处理，异常值处理（条件过滤）
- 2. 数据聚合，使用 pandas、numpy做 RFM 分析，得出 RFM 得分
- 3. 使用 matplotlib 做数据可视化
- 4. 功能迭代：
 - 基于用户订单日志，使用 flume 实时采集订单数据，配置 flume agent 传输到 kafka中。
 - 使用 flink 进行数据处理，实时消费 kafka topic 中的数据，存储分析后的 RMF 数值。
 - 前端使用 echarts 进行分析图表展示，并提供下载功能。

业绩：

采集系统的完成及投入使用。

监测报警系统的完成及使用。

自动下单系统的完成。

实时数据分析，提供用户策略决策数据。

教育经历

长治学院	本科	管理专业	2011-2015
------	----	------	-----------