

Jack

大模型数据处理工程师

电话：15718012216 邮箱：wuhong_uestc@163.com 性别：男 城市：杭州
民族：汉族 政治面貌：中共党员 婚姻状况：未婚



教育经历

杭州电子科技大学	电子信息工程	本科	2015.09-2019.06
电子科技大学	电子与通信工程	硕士	2019.09-2022.06

工作经历

阿里健康科技(杭州)有限公司	大模型数据处理工程师	2022.07-2025.05
阿里巴巴(中国)有限公司	大模型数据处理工程师	2025.06-至今

职业技能

背景经历：拥有4年的数据工程领域工作经验，包括3年大模型数据工程师和1年的数仓经验，专注于大数据处理及大模型数据构建工作。

专业技能：掌握Python、SQL等编程语言，擅长使用Python开发UDF、UDTF以及大模型能力处理数据，具备丰富的数仓开发经验和大模型数据处理能力，能够高效完成数据解析、去重、清洗、加工、重构任务，并有效管理大规模数据集。

综合素质：在项目中展现出强烈的责任心，擅长跨部门沟通协调，具有良好的团队协作精神，能够在快节奏的工作环境中保持高效产出，按时、高质量的交付数据。并且在担任内容库自动化Dump系统项目的PM时，实时追踪整个项目的进度，及时发现可能存在的风险并解决，不耽误整体的进度。

项目经历

HappyHorse视频生成项目-视频数据处理管线搭建	2025.10-至今
-----------------------------	------------

一、项目概述：在HappyHorse视频生成项目中（集团重点项目），构建了一套高效且稳定的视频数据处理管线，旨在确保送入模型的数据既及时又干净。

二、核心职责：负责设计并实现数据存储与处理管线的搭建，协调跨部门团队合作，确保技术方案的有效落地。具体包括视频数据存储、处理效率优化以及数据质量控制。

三、成果亮点：

1、数据处理效率提升：视频数据存储于OSS，为了突破带宽的限制，将视频数据入湖后，后续链路的数据处理效率提高了60%。

2、高效信息提取：构建ffmpeg算子，获取视频的基础信息（时长、分辨率、比特率、文件大小等），采用流式的方式读取头文件信息，800w的视频能在20分钟刷完ffmpeg。

3、LLM分类：对视频数据的标题、描述等文本信息通过LLM模型进行分类，有效过滤了低质数据，提升了数据纯净度。

- 4、VLM分类：对视频进行抽帧处理，并通过VLM模型进行分类，精确筛选出符合模型训练质量标准的优质数据。
- 5、敏捷需求响应：使用Agent开发采集插件，能够灵活、快速地满足临时性的、高优先级的小批量数据获取需求。
- 6、数据可视化监控：搭建数据报表看板，追踪整体及站点级别的数据漏斗情况，以便能看到数据目标的达成情况以及指导采集测的流量分配。

网页数据处理Pipeline重构

2025.06-2025.09

- 一、项目概述：既有的网页数据处理链路存在稳定性差（需要人力频繁运维）以及吞吐量低的问题，并且随着单日的采集量增加（10亿->100亿），整个链路跑完一次需要7天，并且经常会报错，人力介入成本高。
- 二、核心职责：重构网页数据处理Pipeline，提高稳定性、吞吐量、时效性。
- 三、成果亮点：经过对整体链路的重新设计以及细节的优化后
 - 1、整体的处理流程为：HTML去重->HTML转markdown->markdown文本去重->大模型清洗文本->日增MD5去重->日增相似度去重->全量MD5去重->全量相似度去重->质量模型->分类模型
 - 2、时效性：7天->2天
 - 3、日吞吐量：10亿->100亿
 - 4、稳定性：人力运维成本从每周平均9次->1次

医学内容库-自动化更新系统构建PM

2024.11-2025.03

- 一、项目概述：构建自动化处理系统以优化从源数据获取到最终数据交付的流程（解析->打标->chunk切分->要点生成->翻译->质检->去重->引用关联），解决手动操作效率低下的问题。
- 二、核心职责：作为项目PM，负责整个系统的架构设计、模块定义、团队协作以及把控EAS服务部署进度，确保各环节高效衔接。
- 三、成果亮点：
 - 1、实现了一键启动全量数据刷库流程（自动化系统搭建前是靠人工火炬传递）
 - 2、文献全链路运行时长从6天->3.5天，提升42%
 - 3、指南全链路运行时长从7天->2天，提升71%
 - 4、人力从6人->1人，人力节省83%
 - 5、支持单一节点重跑功能，进一步增强了系统的灵活性。

医疗基座大模型-预训练数据处理

2023.09-2024.06

- 一、项目概述：该项目旨在提升大模型在医疗领域的应用水平，通过优化训练数据来增强模型的医学知识和专业术语翻译能力。
- 二、核心职责：负责处理TB级的预训练数据，包括数据清洗、重构、去重等，确保高质量的数据输入；补充并优化医学术语翻译语料库，以提高模型的专业翻译准确性。
- 三、成果亮点：
 - 1、经过处理后的数据显著提升了模型的医学理解能力，在多次的数据迭代后，在医疗自建评测集上相对于base模型总平均分提升了9.5%
 - 2、加入医学术语数据集后，在医学术语翻译方面实现了388.6%的准确率提升
 - 3、技术沉淀：
 - （1）沉淀了一个基于Qwen14b进行continue-train的文本清洗模型(准确率91%)以及key和topic抽取模型(准确率87%)
 - （2）针对个人隐私、网址、文章开头无关信息、文末无关信息、段落重复、标点符号占比过多、空格和换行符冗余等问题，积累了8套基于规则清洗的模版
 - （3）通过数据建模(采、建、管、用)，规范化数据存储和数据流转