

Snow

+86 13611463641 | yizhangdan@163.com | wechat: d13611463641

教育经历

2020.09-2022.06	中山大学数学学院	应用统计学专业	硕士
2016.09-2020.06	华南师范大学数学科学学院	应用统计学专业	本科

工作经历

百度国际科技（深圳）有限公司 - 文心一言模型组 - 算法工程师	2022.07 - 至今
----------------------------------	--------------

多模态视觉感知能力建设：负责文心一言4.5、5.0 多模态大模型感知能力建设。

背景与问题：围绕多模态大模型“看不细、辨不准、理解不全”的问题，提出视觉感知增强方法论，结合图像对比学习、Dense Caption 和视频时序建模，提升模型对复杂图像与视频的细粒度理解能力。

核心贡献：

- 提出基于相对排序的 CLIP 高置信正样本过滤方法，通过局部分布校准与双向 Top-1 一致性检验，从大规模弱对齐 alt-text 数据中筛选高质量图文正样本，降低噪声干扰。
- 设计基于检索排名的分层 Hard Negative Mining 策略，构造强 /中/弱三级负样本，提升模型对实体、属性及相似候选细粒度差异的判别能力，累计生产约 1T tokens 高质量图文对比学习数据。
- 训练 Dense Image Caption 专精模型，规模化生成覆盖实体、属性、位置、关系、场景和文字等视觉细节的低幻觉、高信息密度 caption；最终产出 10M 图像样本，单机 H100 产速约 10 万/天，并反哺多模态 Midtrain 阶段。
- 提出 CaptionRL「你说我猜」训练范式，以 QA 可验证反馈优化 caption policy，将开放式 caption 生成转化为可验证的视觉信息完备性与保真度优化问题，提升 caption 的细节保真度、信息覆盖度与抗幻觉能力。
- 建设高质量 CapQA 体系，覆盖 6 类视觉问题维度，通过全图覆盖、难度控制、多样性均衡和多模型校验保证 QA 质量与 reward 稳定性。
- 将方法扩展至视频模态，设计 Keyframe-Anchored Residual Dense Video Caption pipeline，通过关键帧建模静态视觉信息、残差帧建模帧间动态变化，生成高信息密度 dense video caption，提升模型对运动模式、状态变化和时序动态的理解能力。
- 训练 Dense Video Caption 专精模型并规模化接入视频数据合成流程，使生成数据的信息密度提升约 3 倍，幻觉率由 35% 降至 3%。

成果：

- 图像细粒度感知能力显著提升：图像对比学习策略应用于 ERNIE 4.5 上线版本，多模态 Benchmark 平均提升 3.95%，知识类 MMBench 提升 4.89%，验证了细粒度正负样本构造对视觉知识学习的有效性。
- CaptionRL 显著提升 dense caption 质量与可用性：在自建 CapQA 评估中，CapQA-Domain 准确率从 75.05% 提升至 89.85%；CapQA-Wild 在 17 个通用 Benchmark 上全面提升，验证了 QA 可验证反馈对 caption 信息覆盖度和低幻觉能力的优化效果。
- Dense Caption 数据反哺带来可观 scaling 收益：Dense Image Caption 数据进入 Midtrain 后，在 MMStar、ChartQA 等图像细粒度理解任务上观测到 scaling 提升；Dense Video Caption 数据进入 Midtrain 后，在 VideoMME、TempCompass 等视频理解与时序推理任务上观测到持续增益。
- 方法论规模化上线并支撑旗舰模型能力升级：相关策略持续迭代并上线至 ERNIE 5.0，支撑模型在 LMArena 视觉理解榜单中取得国内领先表现，整体视觉理解能力进入国际头部多模态模型梯队。

音频大模型能力从0到1建设：负责文心一言5.0 音频理解能力从0到1建设。

背景与问题：围绕传统 ASR+LLM 难以保留语气、情绪、说话人和环境声等声学线索的问题，建设 ERNIE 5.0 端到端音频理解能力，形成旗舰版与轻量版双模型方案，提升音频语境理解与推理效率。

核心贡献：

- 建设真实场景驱动的 ASR 鲁棒性方案，覆盖噪声、远场多人、口音方言、code-switching、长音频与专业热词等场景，通过语料构建、弱标注质控、音频增强和规则改写提升识别泛化能力。
- 提出音文模态对齐诊断与自蒸馏优化方法，用 KL divergence 量化音频 / 文本推理分布偏移，并通过

双粒度RL方法将模态 gap 从 8% 降至 3%。

- 构建副语言理解 RFT 数据闭环，设计 Dense Caption、指令合成与多模型 Verify Pipeline，产出 2500 小时高质量副语言数据，增强情绪、语气、语速、停顿与意图理解能力。
- 主导 Eureka-Audio-1.7B 孵化，将 ERNIE 5.0 音频方法论迁移至轻量级模型，验证低成本音频推理方案，并推动模型开源与技术报告发布。
- 提出 MoE Adapter 架构缓解异质音频梯度冲突，相比 Dense Adapter 在 MMSU / OBQA / MMAU 上提升 3.16% / 3.75% / 1.71%。

成果：

- ERNIE 5.0 ASR 超 Gemini-3-Pro，字错误率降低 2.42%；MMAU（副语言理解能力）达 80.4分，与 Gemini-3-Pro 80.8分 基本持平；VoiceBench 70.18分，超过Qwen3-Omni-30B-A3B-Instruct。
- Eureka-Audio-1.7B MMAU 达 74.67 分，超越开源竞品 Qwen3-Omni-30B-A3B-Instruct；解码速度 269.7 tokens/sec，比 Qwen3-Omni-30B-A3B-Instruct 快 3.7 倍，建立了轻量级音频理解模型的学术标杆。
- 一作技术报告已公开发表，ACL 1 篇。

文本模型高阶推理能力体系构建：负责文心一言4.0、5.0 文本模型高阶推理能力建设。

背景与问题：通用预训练语料中高质量推理数据分布稀疏、能力覆盖不均，且缺乏系统化的能力体系指导数据挖掘、筛选与配比，导致推理能力提升较依赖数据规模扩张，专项能力迭代效率和效果归因存在瓶颈。

核心贡献：

- 主导构建 ERNIE 4.0 预训练高阶推理能力体系：从模型完成复杂任务所需的思维能力出发，反推预训练阶段应具备的能力图谱，将抽象的推理能力拆解为可观测、可度量、可归因的数据特征，为推理类数据建设提供统一标准。
- 创新提出“语料编目法”：对数据进行能力建模，聚焦提权高质量推理语料，解决传统数据采样中高价值推理数据被长尾语料稀释的问题。
- 设计全链路推理能力框架：构建覆盖指令理解、问题分解、规划推理、答案生成、表达论证、自我审视的能力闭环，系统刻画模型从理解任务到完成复杂推理的关键能力。
- 建立数据挖掘、配比与归因机制：将能力体系落地到预训练数据生产流程中，支持不同推理能力维度的数据调控、实验分析和效果归因，提升推理能力建设的可解释性和迭代效率。

成果：

- 显著提升模型推理能力：能力体系上线至 ERNIE 4.0 预训练数据建设，推动模型在 BBH、ARC、GSM8K、MATH、MMLU、CMMLU、C-Eval 等推理类 Benchmark 上平均提升 35%，验证了专项能力数据建设对复杂推理、数学和知识泛化能力的有效性。
- 方法持续复用至 ERNIE 5.0 旗舰模型：相关策略延续应用于 ERNIE 5.0，支撑模型在 LMArena 文本榜中取得国内第一、全球第八，超过GPT-5.1-High、Gemini-2.5-Pro等国内外主流模型；数学能力位列全球第二，仅次于 GPT-5.2-High。
- 形成公司级标杆能力建设项目：该专项成为首个突破 Scaling Law 瓶颈的能力方向，并获得公司最高级别奖项“百度最高奖”（公司全年仅 4 个）。

论文及技术报告

- Dan Zhang, ... & Haifeng Wang. *Eureka-Audio: Triggering Audio Intelligence in Compact Language Models*
- Yishu Lei, Shuwei He, Jing Hu, Dan Zhang, ... & Haifeng Wang. *MoE Adapter for Large Audio Language Models: Sparsity, Disentanglement, and Gradient-Conflict-Free*

奖项

- 公司内获奖10次：百度最高奖（公司全年仅4个）1次、百度骄傲（公司级）2次、个人奖（部门级）2次、项目奖（部门级）5次。

能力

全模态大模型、音视频理解、数据策略、强化学习、Prompt工程