

邢雨涵

电话：18845156179 | 邮箱：hanhhcat@163.com

生日：1999-06 | 性别：女

求职意向：大模型数据工程师/后端研发工程师

工作经历

- 蚂蚁金服** 2024年09月 - 至今
软件开发工程师 AI数据处理 北京
工作描述：技术栈Python/SQL，主要负责百灵大模型预训练阶段的文本数据处理工作，提升数据清洗数量、质量、效率，并研发非结构化数据处理平台。
- 字节跳动** 2023年12月 - 2024年06月
后端开发工程师 Data 北京
工作描述：技术栈Go/Python，主要参与事抖音内容安全治理的算法架构工作，参与模块迁移、承接需求以及维护日常架构稳定性。
- 百度** 2022年07月 - 2023年12月
C++开发工程师 IDG智能驾驶事业群组 北京
工作描述：技术栈C++/Python，主要从事自动驾驶数据挖掘的工程维护与策略开发、相关任务流开发建设、挖掘pipeline的开发与维护以及下游数据指标的生成与分析。

项目经历

蚂蚁金服 - 百灵大模型数据处理与质量优化

个人职责：构建网页/百科/书籍/论文等非结构化数据处理管线，包括PDF文档高精度解析模型训练；通过规则+模型等方式对低质数据进行改写和过滤，显著提升了最终交付给大模型训练的数据纯净度。

重点项目：

- Text Refine**
 - 模型训练**：使用ms-swift框架微调 Qwen3-4B，通过教师模型蒸馏、Badcase 定向数据合成及路由分类器机制，从而提升模型效果。
 - 模型部署**：利用 GPTQ 量化技术 将模型显存从 8G 降低至 2.5G，使其适配生产环境的GPU (A10/L20)，并封装通用 Spark 算子支撑海量数据的高效回刷。
 - 评估体系**：构建多维指标的 Benchmark 及可视化看板，利用 TinyLlama 完成自验证，中英文网页 10+ 核心训练集质量标准提升至A级，消融实验部分榜单正向明显 ($> +0.5pt$)。
- 高质筛选模型特征 - bradley**
 - 简介**：构建了包含写作风格、教育价值等四大维度的评分体系，基于多模型对文本pair对进行偏好打分，引入 Cohen's Kappa 系数量化样本置信度，筛选高质量文本语料。最终，训练 BERT 模型自动化完成四维度的质量打分。
 - 收益**：该特征成功覆盖10+核心业务链路，将500万高质站点的低价值噪声占比从62%大幅压缩至11%，显著提升了数据质量。
- pdf解析模型 - PrismOCR**
 - 模型训练**：针对多栏文本、无边框表格等疑难场景，通过程序化反向合成 Badcase 并结合 CLIP-Embedding 聚类筛选，构建高多样性训练集。引入 RFT拒绝采样机制进行多模型交叉蒸馏，采用VL模型微调的两阶段监督微调策略，并训练多模型路由系统实现对于专家模型池的智能路由。
 - 智能迭代**：搭建模型自升级的自动化链路，打通“业务 Badcase 收集 -> 数据清洗/合成/蒸馏 -> 模型微调 -> 自动化评测 -> 新模型部署”的全流程，实现了模型能力的持续快速迭代。
 - 评估体系**：在自建榜单上，PrismOCR 在26个细分评测维度中，取得了15项最佳成绩，在核心业务场景（医疗、金融等）中性能优势明显。

蚂蚁金服 - 百灵大模型数据处理基建

个人职责：技术栈Python/Java，构建标准化处理算子/组件，数据处理链路agent化，参与非结构化数据处理平台后端建设，参与构建算子研发体系。

重点项目：

- **去污组件性能优化**
 - **痛点：**使用minhash+lsh技术方案，之前使用 SQL-Join 导致数据极度膨胀，导致2w 台机器跑 10 h，存储上涨 50x。
 - **优化方案：**用 antspark cacheModel 把榜单全量广播进内存，以 For-Loop 替换 Join，彻底砍掉中间表与 Shuffle；切词引擎 jieba → bt2，取消长度限制；删除榜单中的模版术语；集成增量去污；引入倒排索引 + Jaccard 引擎，将"逐条比对"变成"直接查表"，减少计算冗余；采用内存映射（mmap）技术按需读取；智能预设参数，以防用户使用极端参数造成集群资源浪费。
 - **效果：**全量去污提升7.6倍，核心去污提升55倍；内存占用，全量去污下降一倍，增量去污下降4倍，且 Benchmark中的6000+负样本全部召回。

字节跳动 - 抖音机审算法架构迁移与重构

个人职责：技术栈Python、Go，从0到1开发并设计标签生产框架；开发特征处理算子，迁移主要审核算法场景；参与模块稳定性治理工作，优化部分迁移场景耗时过长问题，并进行功能升级。

重点项目：

- **标签生产框架研发：**从0到1开发并设计整个框架，实时从上游获取直播评论信息，经过模型预测和数据后处理，开放业务方定制逻辑入口，生成标签信息入hive表；
- **场景迁移：**迁移主要审核算法场景，逻辑复杂，特征数目巨大（3k+），最终消除diff至0.01%下并合理归因。

百度 - 自动驾驶数据挖掘

个人职责：技术栈C++、Python，从0到1的开发离线/车端数据挖掘框架，进行核心业务逻辑迁移，成功接入17条核心挖掘任务流；开发例行挖掘任务流和自定义数据挖掘sdk服务；构建覆盖全链路的自动驾驶场景标签体系，并进行场景参数化探索。

项目亮点：

- **离线挖掘性能优化：**使用单例模式，引入内存池，动态加载地图/行驶数据，优化业务逻辑和代码，减少内存拷贝，规范工程开发。最后任务运行时长减少至50%，运行内存占用减少13%，线上任务90分位点平均耗时 < 3h；
- **例行挖掘任务流：**负责搭建并维护发起任务、数据入库、监控机制等服务，使用Python进行开发，Redis记录订单流转状态，挖掘数据写入ES/afs，日均T+1生产40w+标签，持续稳定赋能下游指标、训练等。

教育经历

哈尔滨理工大学

2018年09月 - 2022年06月

计算机科学与技术 本科 全日制

个人技能

- **数据工程：**熟悉文本大模型预训练数据处理全流程，熟悉规则+模型优化数据质量并深入实践。
- **语言：**有Golang、C++、Python长期实际开发经验，了解Golang GMP、map、slice等底层原理，了解C++基本语法，有Java开发经验。
- **基础知识：**熟悉操作系统、网络编程等基础知识，比如进程线程协程、调度算法等，掌握链表、栈、队列、二叉树等常见的数据结构。
- **后端组件：**熟悉MySQL索引与事务机制，掌握Redis核心数据结构、持久化及分布式锁应用，并了解Kafka等消息队列的高性能架构与可靠性保障方案。
- **工具：**熟悉Linux环境下的常用命令和Git基本使用，长期基于Linux平台下进行工程开发。

个人总结

本人学习能力很强，喜欢钻研技术，英语能力较好（英语水平六级），善于沉淀和总结，会去主动学习新知识。