



基本信息

姓 名：邱文杰
性 别：男
求职意向：大模型数据工程师
邮 箱：13032989457@163.com
年 龄：28岁
工作年限：7年经验
电 话：13032989457



教育背景

2015-09 ~ 2019-06 西安电子科技大学 (211) 计算机科学与技术 (本科)

技能特长

- 1.熟悉离线和实时数据处理过程，熟悉维度建模，lambda架构，有多次离线和实时数仓搭建经验
- 2.熟悉数据治理过程，包括元数据管理，数据质量管理，数据集成管理，数据血缘等
- 3.熟悉主流的大数据处理框架，包括 Mapreduce, Hive, Spark, Flink, Trino, duckdb等
- 4.熟悉常见的数据存储系统，包括 Hdfs, Kafka, Hbase, Mysql, OSS, 以及数据湖框架iceberg等
- 5.熟悉多种任务调度系统，包括 Oozie, Airflow, Datastudio, DataWorks等
- 6.熟悉Linux环境以及Shell脚本开发，以及常见的编程语言Sql, Python, Java等
- 7.熟悉分布式集群环境以及分布式任务开发，熟悉ray core、ray data等
- 8.熟悉vibe coding以及ai agent，重度使用cursor、claude code

工作经验

- 2019-07 ~ 2021-05 深圳市房多多网络科技有限公司 大数据开发工程师
- 所属部门：数据中台
 - 主要职责：
 - 1.负责离线数据仓库的架构设计与开发
 - 2.参与实时数据服务开发
 - 3.参与大数据平台的维护与开发
- 2021-05 ~ 2023-03 深圳市虾皮信息科技有限公司 大数据开发工程师
- 所属部门：Search&Rcmd 数据团队
 - 主要职责：
 - 1.负责直播业务离线&实时数据仓库的设计、开发和治理
 - 2.对接BI及local业务团队，提供数据支持和分析答疑
 - 3.对接算法团队，负责推荐实验的数据支撑和效果回收
- 2023-05 ~ 2025-02 上海市米哈游天命科技有限公司 大数据开发工程师
- 所属部门：数据平台组
 - 主要职责：通过米哈游海量游戏用户数据以及外采数据，支撑用户增长、市场、国际化、游戏项目组等多个业务方的数据需求，主要项目有：
 - 1.负责游戏舆情业务实时数仓的搭建
 - 2.负责用户标签画像系统的建设
 - 3.负责游戏KOL业务的数据处理
- 2025-03 ~ 至今 上海市米哈游天命科技有限公司 大模型数据工程师
- 所属部门：ai大模型部门
 - 主要职责：主要负责音频模态数据从采集到模型trainable之前的全链路数据处理，为各个语音大模型提供训练和评测数据，包括：架构设计，数据处理管线搭建，算子开发与调优，模型调用与部署，数据存储与入湖，数据的抽样和标注，特征提取，训练集和eval集构建等

对话音频数据处理管线

米哈游(大模型)

项目介绍：为各类基础音频大模型包括tts, asr, understanding, 以及端到端的omni语音大模型, 全双工语音大模型等, 构建数千万小时的pretrain对话音频训练集

技术架构: ray、spark、iceberg、mlp、vllm、pytorch、cursor、claude code、sophon

主要职责:

- 1.搭建高并发的对话音频数据处理管线, 开发和迭代各类数据处理CPU/GPU 算子
- 2.对采集到的海量原始数据做清洗, 裁剪, 转化, 打标, 过滤等
- 3.调度运维数千张小卡运行清洗任务
- 4.提取音频特征并构建pretrain, sft等阶段的训练集、eval 集
- 5.设计数据存储与元信息管理方案, 方便算法团队预览与分析

音乐数据处理管线

米哈游(大模型)

项目介绍: 搭建音乐数据处理管线, 对数千万首歌曲进行清洗, 为音乐大模型构建上百万小时的音乐训练集与评测集。

技术架构: ray、spark、iceberg、mlp、vllm、pytorch、cursor、claude code、sophon

主要职责:

- 1.搭建高效的音乐数据清洗管线, 开发歌声处理算子。
- 2.清洗数千万首歌曲的meta信息和音频文件
- 3.提取歌声特征并构建音乐训练集、eval 集
- 4.对数据进行分析过滤, 支持算法测决策

多模态数据标注与处理管线

米哈游(大模型)

项目介绍: 搭建统一的数据处理标注管线, 产出并处理organic数据集, 处理并送标中文/英文、单工/双工、音乐、影视等多类型数据, 构建 SFT 训练集与 eval 集。

主要职责:

- 1.通过数据管线和数据湖统一处理和管理不同类型不同数据源的数据
- 2.使用策略抽取高质量数据并送标
- 3.对人工标注后的数据进行处理, 检验和入湖
- 4.构建organic数据处理过程, 产出高质量的sft训练集与eval集

舆情数据实时数仓建设

米哈游(数据平台)

项目介绍: 公司旗下多款游戏(原神、星穹铁道、绝区零)在国内外主流社媒平台有大量用户互动, 需要实时监控舆情, 及时发现重大负面事件, 支持版本更新反馈分析以及米游社内部言论管控。

技术架构: 爬虫采集 → kafka → Flink → Iceberg → ES/MySQL

主要职责:

- 1.从爬虫端采集海量社媒原始数据, 设计数据清洗与加工流程。
- 2.使用 Flink 搭建实时数仓, 保证数据时效性。
- 3.将处理结果写入 ES/MySQL, 供舆情平台实时查询。
- 4.支持业务方实时管控舆情、分析用户反馈。
- 5.舆情监控延迟控制在分钟级, 重大事件可实时预警。支撑多个游戏版本更新后的用户反馈分析, 提升运营响应速度。

标签画像系统建设

米哈游(数据平台)

项目介绍: 构建公司游戏用户的实时与离线画像, 支持营销、市场、业务分析等场景。

技术架构：Spark、Flink、Iceberg、Redis

主要职责：

- 1.设计用户画像数据模型，处理上游游戏数仓表数据。
- 2.计算实时标签与离线标签，提供查询、分析、导出功能。
- 3.支持 ToC 场景（流失用户召回、消费潜力用户触达）与 ToB 场景（内部业务分析）。
- 4.标签计算延迟缩短至分钟级，实现实时营销触达。
- 5.构建上千个业务标签，覆盖用户生命周期管理。

直播业务实时与离线数据仓库搭建

shopee

项目介绍：直播是shopee内容电商中日益增长的重要模块，为了解用户观看直播的喜好，分析用户的下单路径，给主播提供数据反馈，给local团队提供精细化运营，基于业务库数据和用户行为埋点日志，建立Livestream Mart & Livestream Realtime Mart

离线数仓： datahub+ hdfs + hive + spark + airflow + marker + datastudio

- 1.通过datahub导入业务库数据，通过小时级etl任务获取用户行为日志
- 2.使用hdfs+hive+spark的离线数仓架构，采用维度建模法，以星座模型为基础进行数据建模
- 3.数仓根据数据处理纵向分为ods、dwd、dim、dws、ads五层，根据业务逻辑横向划分ls_session、streamer、viewer、order、abtest等domain
- 4.dwd层采用退维的方式减轻dws层的逻辑冗余，dws层采用宽表拆分来提升sla
- 5.使用airflow来调度计算任务，后迁移至datastudio
- 6.使用marker服务提供表级血缘关系的依赖支持

主要职责：

- 1.设计与开发离线数仓的项目架构
- 2.开发数据模型，包括五步归单、直播观看时长、直播间宽表等
- 3.对接算法团队，提供推荐实验的数据支撑和效果回收
- 4.优化spark任务，保障调度任务的SLA

实时数仓： datahub +mysql + kafka + hbase + iceberg +flink

- 1.用户行为日志的数据源是kafka，业务库数据通过datahub以cdc的方式实时摄取至kafka+iceberg
- 2.以flink作为实时数据的计算引擎，kafka/hbase/iceberg/mysql作为数据存储
- 3.维度数据采用lookjoin的方式点查
- 4.通过滑动窗口计算分钟级指标
- 5.通过keyby、状态管理以及update-kafka实现直播间维度的指标
- 6.明细层数据采用打标的方式来优化后续统计

主要职责：

- 1.设计与开发实时数仓的项目架构
- 2.开发直播场景下的实时数据，包括主播看板，运营大屏，监控报表等
- 3.负责维护项目的稳定性，保证秒级数据延迟