

钱银龙

手机号: 18810836089 | 邮箱: ylqian07@163.com
技术方向: 多模态理解和生成, 图像和视频内容理解

教育背景

- 2011.09-2017.12 中国科学技术大学, 信息学院, 自动化系, 工学博士 (导师: 谭铁牛院士, 中科院自动化所联合培养)
- 2007.09-2011.07 中国科学技术大学, 信息学院, 信息安全专业, 工学学士

工作经历

2025.04-至今

道通智能航空

● 多模态理解大模型

- 项目目标是建设安防场景行业多模态大模型, 满足安防行业场景图片、视频的理解分析需求, 包括图像/视频内容理解、事件时序定位、目标空间定位、态势推演预测等。
- 本人负责搭建从数据构建到模型训练评测的整体方案。数据构建的重点工作包括: 1) 针对无人机场景安防图片/视频数据较稀缺的问题, 通过构建仿真/合成管线扩充长尾数据, 如通过仿真环境生成可控的追逐、集结事件, 基于生成编辑工具合成异常行为图片/视频等; 2) 构建清洗去重、模型打标/重写、质量控制 (规则/模型过滤、拒绝采样、难例挖掘等) 等数据工程进行规模化高质量数据生产。训练策略方面, 基于 CPT+SFT+RL 训练范式基础上结合任务特点进行优化, 包括引入长度自适应采样 (fps/帧数/分辨率随序列约束动态调整) 与课程式配比 (不同长度、难度的视频) 提升模型综合能力。RL 训练阶段重点采用 RLVR 方式, 覆盖时空定位 (IoU、时序关系)、证据引用完整性与一致性, 提升可执行可解释性。
- 最终在内部构建的垂类业务场景事件理解、人员行为分析平均准确率 92%, 精度指标优于 Qwen2.5-VL-7B 模型 10 个点左右。

2020.03-2025.04

美团 M17

● 多模态大模型基座 (理解、生成)

■ 理解、生成统一多模态大模型:

- 目标是构建兼具多模态理解和生成能力, 并实现理解和生成能力协同促进的统一模型。本人负责理解与生成统一的模型架构和训练方案, 基于美团 LongCat-VL 底座, 选型并验证 “VLM + Diffuser” 的架构, 引入轻量化 adapter, 并精调 mid-training 和 SFT 训练策略和数据配比, 可维持图文理解能力, 且支持文生图、编辑、交错图文生成等生成任务。
- 数据侧, 主导构建大规模训练数据: 融合开源与自采数据, 并搭建数据管线, 实现质量控制与覆盖提升。具体包括清洗去重 (如针对生成数据进行分辨率、水印、安全、美学分过滤等)、基于 VLM/LLM 进行指令/caption 重写、质量过滤 (基于图文对齐、LLM/VLM-as-a-judge), 长尾覆盖提升 (数据合成、concept-balanced resampling) 等, 产出 5 千万 mid-training 与 500 万 SFT 高质量理解、生成混合配比数据。
- 训练侧, 系统验证 VLM + Diffuser 从 mid-training 到 SFT 的多阶段训练策略。具体包括: 1) 双头多任务 (具体包括理解任务文本 NTP 和生成任务 control embedding 预测) 联合训练范式下的 embedding 训练方案及多任务间 loss 权重配比。embedding 训练方案包括视觉 semantic embedding 和文本 control embedding 两种监督方案; 2) 多任务的 multi-stage 训练策略 (包括 mid-training 和 SFT)。结合任务/数据难度, 分阶段逐步引入理解、文生图、交错生成、参考生成/编辑等任务, 并验证数据配比策略 (包括分布平衡、长尾数据增强等)。最终在基于公司自研 LongCat-VL 基座和 MT-DiT 生成模型基座基础上, 构建了文本生成和图像生成统一大模型, 其在保持视觉理解能力情况下, 同时实现图像生成能力对标 SD XL。

■ 面向图像编辑、生成的理解大模型

- 项目目标是基于主流 VLM+DiT 框架构建自研图像生成/编辑大模型。本人主要负责优化提升作为语义条件控制模块的 VLM 能力, 其作用是基于用户输入的 query 或参考图像, 输出包含语义信息的 embedding, 作为后续 DiT 的条件控制。基于 Qwen2-VL-7B 基模, 重点优化改进: 1) 用户自然语言 (短 prompt, 或+参考图) 输入时, 模型可以输出蕴含构图、细节、空间编排等细粒度语义 embedding (回归任务, 回归结构化 caption 的 embedding), 从而提升后续 DiT 模块图片生成质量; 2) 对于用户输入, 可以精准识别任务场景/类别 (分类任务, 可区分生成、编辑、参考生成

等)。

- ◆ 数据侧重点构建高质量<用户query(或+参考图), 场景类别+结构化caption>对, 考虑了2种构造方式: 1) 基于高质量图片通过VLM进行detailed caption打标, 再进一步按场景转成结构化caption, 并生成用户query。2) 基于真实用户query (或+参考图) 经微调的VLM Captioner生成结构化caption (含CoT和非CoT版)。
- ◆ 最终交付的理解大模型对于VLM+DiT整体方案在生图质量上(构图、细节控制、角色一致性等方面)有明显提升。

● IoT 场景图像视频理解分析

- ◆ 项目总体背景为美团多个线下业务部门如网约车、客服、无人车等, 对IoT 监控摄像头的智能图像/视频分析有较多的业务需求。针对该类需求, 通过和硬件及工程部门合作, 共同打造软硬一体化的智能摄像头解决方案, 以满足业务智能监控分析需求。
- ◆ 本人主要负责软硬一体方案中针对不同业务场景的端云算法能力构建, 包括人体细粒度分析(检测、分割、Re-ID、表情动作识别、属性识别等)、行为检测(疲劳驾驶、异常行为等)、画面质量检测等。具体工作包括和硬件部门同事配合完成摄像头和芯片的选型, 完成从算法选型、数据构建(采集、回流、标注等)、训练优化及评测整个流程, 和工程侧同事合作完成模型量化和端云部署, 并最终落地到美团网约车“美视”项目、云客服异常行为监控项目、自动车远遥驾驶异常行为监控项目等多个线下业务。

2017.12-2020.03

三星北京研究院

● 图像/视频理解

- ◆ 总体目标是在基于DVS相机的物体/行人检测算法研究开发, 实现在智能家居、家庭安防/监控等场景的产品开发应用。
- ◆ 本人主要负责人体分析相关检测算法的设计、训练数据采集标注构建、模型训练及模型压缩。提出了一种针对DVS相机成像特点(对运动motion信息敏感、稀疏性、高噪声、appearance差异大等)的基于深度学习的轻量级物体检测方法, 并结合Distillation(蒸馏)等模型压缩手段进一步减少模型尺寸, 适配硬件算力需求。最终完成基于猎户座芯片+DVS摄像头的异常行为监控智能家居单品交付, 并加入了三星SmartThings智能家居平台。

近期论文

- Jiao S, Zhang G, **Qian Y**, et al. FlexVAR: Flexible Visual Autoregressive Modeling without Residual Prediction, NeurIPS 2025.
- Jiancheng Huang, Gengwei Zhang, Zequn Jie, **Yinlong Qian**, Ling Chen, Yunchao Wei, Lin Ma, “M4V: Multi-Modal Mamba for Text-to-Video Generation”, CVPR 2026, accepted.
- Wei Zhou, **Yinlong Qian**, Zequn Jie, Lin Ma, “Multi View Action Recognition for Distracted Driver Behavior Localization”. CVPRW 2023.
- Wang, H., Ren, P., Jie, Z., Dong, X., Feng, C., **Qian, Y.**, Ma, L., Jiang, D., Wang, Y., Lan, X. and Liang, X. Ov-dino: Unified open-vocabulary detection with language-aware selective fusion. arXiv preprint arXiv:2407.07844
- **Yinlong Qian**, Jing Dong, Wei Wang, and Tieniu Tan, “Feature learning for steganalysis using convolutional neural networks”, Multimedia Tools and Applications 77.15(2018):19633-19657.
- **Yinlong Qian**, Jing Dong, Wei Wang, and Tieniu Tan, “Deep Learning for Steganalysis via Convolutional Neural Networks”, Proc. SPIE, Electronic Imaging, Media Watermarking, Security, and Forensics 2015, vol. 9409, San Francisco, CA, February 8-12, 2015.