

何旺贵

+86 17621619498

| mhttxgm@gmail.com

| [Google Scholar](#)

教育背景

上海交通大学 · 硕士
华中科技大学 · 学士

2016.09 – 2019.03
2012.09 – 2016.07

工作经历

阿里巴巴 – 淘宝内容 AI

2023.01 – 至今

统一多模态模型预训练 / 视觉生成后训练, 以一作/*Project Lead* 发表多篇顶会论文 [Google Scholar](#)

- **统一多模态模型预训练**: 负责统一多模态模型的预训练研究, 处理预训练数据达数十亿, 持续构建高质量、多样化、大规模数据集, 架构尝试包括 AR、AR+Diffusion、MLLM+DiT 等。主导 LoomVideo 统一视频生成编辑模型的数据构建与第一阶段训练, 收集整理千万级多任务数据, 5B 参数在电商时尚场景达 SOTA
- **视觉生成后训练**: 负责电商图像生成平台的模型开发与系统建设, 包括图片生成模型 SFT 训练与蒸馏, Reward 模型建设和后训练, 端到端系统搭建

阿里巴巴 – 淘宝内容算法

2019.04 – 2022.12

多模态预训练与内容理解

- 负责淘宝直播/短视频场景下的多模态预训练模型构建 (VLM/CLIP/BLIP 系列预训练与微调, 对比学习, 视频多模态理解, 模型量化与部署), 支持标签分类、内容召回、视频挂品等业务, 人均点击 +1.8%, 冷启主播曝光 +25%
- 早期负责商品/内容搜索链路中 query 理解、相关性、召回、排序等模型与策略研发 (BERT 相关性模型, CTR/LTR 排序模型)

代表项目

1. 统一多模态模型预训练

LoomVideo: 统一视频生成与编辑模型

2026 年

提出高效 5B 参数统一架构 (Qwen3-VL 8B + Wan2.2 DiT 5B), 通过**逐层 Cross-Attention** 将 MLLM 每层特征注入 DiT 对应层, 实现深层语义对齐, 支持文生视频、指令编辑、参考图生成等多任务。**负责数据构建和第一阶段训练, 搭建训练框架代码**: 收集整理千万级图像/视频生成与编辑数据, 涵盖文生图、文生视频、指令编辑、参考图编辑、多参考图生成等任务, 构建数据处理与质量筛选流程, 制定多阶段数据配比策略; 完成第一阶段 MLLM Alignment 训练, 实现 Qwen3-VL 与 DiT 的语义对齐。三阶段渐进训练, 在电商时尚场景达 SOTA, 性能媲美 13B 级模型。

MARS: 纯 AR 统一多模态模型

2023 年, 一作

最早将 MoT 应用于图像生成, 早于 SD3/MoT。冻结 LLM + 可训练 Visual Expert 共享 Attention, 避免灾难性遗忘, 从零训练图像生成能力。十亿级数据处理与千万级数据合成, 三阶段渐进训练 (256→512→1024px)。7B 参数达 Parti-20B 同等效果, FID 超 SDv1.5, 支持中英文图文联合生成。发表于 [AAAI](#)。

FUSE: MLLM+DiT 统一多模态模型

2025 年, *Project Lead* / 一作

提出 MLLM + DiT 的通用图片编辑统一框架, 早于 QwenImage。设计 SD-Connector 将 MLLM 高层语义与 VAE 细粒度视觉特征预融合, 避免语义瓶颈和低层捷径问题。提出 Adaptive-GRPO, 按去噪时间步自适应分配语义/细节奖励权重。发表于 [AAAI](#)。

MINT: AR+Diffusion 统一多模态模型

2024 年, *Project Lead* / 一作

AR+Diffusion(原生多模态 Early Fusion): 提出 FoXperts(按功能分配专家) 架构解耦视觉理解与生成的优化冲突, 构建千万级多模态理解数据和亿级图片生成数据完成预训练, 并引入 MCoT(Planning→Acting→Reflection→Correction) 模拟人类艺术创作流程。**成功应用于虚拟试鞋, 参考商品场景化生成等任务**。论文详见 [arXiv](#)。

构建亿级多模态数据集, 完成从小模型到大模型的分阶段预训练体系, 支撑多个业务场景。

- 端到端小模型: Video-Swin + RoBERTa-Tiny, 支持分类与召回
- 大模型预训练: CLIP/FLIP → VideoBLIP(Q-Former + 自研 VTTG/VideoFLIP 任务)→ VideoGLM(ChatGLM-6B + Instruction Tuning), 下游分类任务 finetune 准确率从 35% 提升至 77%
- 业务落地: 标签分类、内容召回、视频挂品、看点切片等, 人均点击 +1.8%, 冷启主播曝光 +25%

2. 视觉生成后训练

PromptEcho Reward

2026.04, 一作, Preprint

提出无标注 reward 范式: 将冻结 VLM 交叉熵损失直接作为 T2I RL 的 reward, 零标注零训练, 可随 VLM 升级自动提升。未针对任何公开 benchmark 训练的情况下, 提升基模 (Z-Image, QwenImage) 通用 prompt following 能力: 相对基模净胜率 +26.8pp/+16.2pp, GenEval 0.75→0.82, DPG-Bench/TIIFBench 一致提升, 全面优于 VLM 直接打分 (+26.8pp vs -3.3pp)。海报文字渲染准确率 68%→75%, 验证通用 reward 范式潜力。论文详见 [arXiv](#) / [GitHub](#)。

电商海报生成平台

日均万级调用

独立负责全流程电商海报生成系统搭建: 数据收集与处理 → SFT → 蒸馏 → 后训练 → 量化 → Prompt 增强 → 自动评估, 效果超过 Banana Pro。

- **数据构造**: 百万级数据处理; 从优质海报中提取商品主体, 逆向构造训练样本; 聚类去重; 利用 VLM 推断编辑中间指令进行打标
- **模型训练**: SFT(支持 8 图输入), 蒸馏加速 (DMD/GAN/APG), 后训练 (DPO/GRPO/GDPO/AWM) 优化文字和指令遵循能力
- **生成链路**: Prompt 改写 (CoT)→ 模型推理 → 自动评估, 形成端到端闭环
- **Meanflow Distillation**: 自研基于 Meanflow 的蒸馏方法, 通过巧妙的 LoRA 参数化设计让模型架构自动满足 MeanFlow 的边界条件, 免去原版从头训练和 JVP 计算的开销, 仅需简单的一致性损失即可完成蒸馏。40 步 → 8 步, 5 倍加速, 几乎无质量损失
- **评测**: 构建评估体系, 人工盲评胜率 22.0% vs Banana Pro 21.2%; Gemini 评估通过率 64% vs Banana Pro 59%

人物/参考生成

绘蛙平台“网红打卡地”功能

- **人物模型**: 数据收集, 推理优化 (APG/Dynamic Threshold/CFG Zero), SFT + GAN Loss(ADD/LADD) 改善细节和真实性
- **参考生成**: OminiControl + PulID + Redux 实现换脸换衣与场景一致性保持, 解决多条件数据集难收集问题
- **后训练**: 组图数据构建训练对, 人脸相似性作为 reward 优化一致性
- 在美感、自然度、真实度等维度优于 Banana Pro, 已上线服务创作者