

倪浩

男 | 理想汽车 算法工程师
13021240755 nihaowhut@qq.com

工作经验&教育背景

2023.12-至今	理想汽车	算法工程师	基座模型(语音合成)
2021.05-2023.12	快手	算法工程师	多媒体内容理解 MMU(语音识别)
2018.12-2021.05	字节跳动	算法工程师	AI-LAB(语音识别)
2017.07-2018.12	科大讯飞	研究员	AI 研究院(自然语言处理)
2014.09-2017.06	中科院自动化所(保送)	硕士	模式识别国家重点实验室(语音识别)
2010.09-2014.06	武汉理工大学(top 2)	本科	自动化

项目经验

2023.12-至今 TTS 基座模型构建与优化（理想汽车）

项目介绍：理想公司拥有丰富的语音交互场景（汽车、智能眼镜、app），需要 TTS 作为播报作为输出。TTS 模型采用 GPT+Decoder 结构，其中 GPT 负责生成语音 token，Decoder 将 token 转成语音。我负责 TTS 模型 GPT 和 Decoder 两大核心模块的架构设计、训练优化，构建适配多场景的高性能 TTS 基座模型，最终 TTS 延迟控制在 120ms；同时搭建了数据处理 pipeline，获取有效数据 100wh。

- **数据 pipeline：**从苹果播客、小宇宙、youtube 和喜马拉雅等获取超 200wh 原始数据，数据 pipeline：转码→降噪→vad 切分/说话人分割→ASR→过滤(非人声、机器配音、低质音频)
- **GPT 优化：**在 GPT 的输入中，逐帧加入 speaker emb，提升说话人相似度；文本和 speech token 交织输入/输出，实现流式 TTS，降低延迟；使用 dpo，减少多度/漏读；将 GPT 升级为 GPT-FLOW 结构：将 GPT 输出的 hidden state 作为 flow 的输入，极大提升了韵律表现；FLOW 加速：将循环次数从 20step 降低至 5step，音质没有明显损失。
- **Decoder 优化，**采用 VITS+Hifigan 架构，多种方法解决电音问题；将模型结构从 causal 改成 uncausal+smooth 降低 WER 0.1 个百分点、提升 UTMOS 0.01 个百分点；延迟控制在 10ms 内；支持多角色音色自定义；

2024.10-至今 播客业务从 0 到 1 搭建与迭代

项目介绍：可以根据给定的主题或者新闻生成双人播客，我主导播客业务全流程建设，覆盖数据收集、模型训练、服务部署及多版本迭代，聚焦“自然拟人化”核心需求，拓展双人播客等新场景，构建完整业务闭环。

- 首个版本通过自研音色克隆模型生成百小时微调数据，解决原始数据不足问题，基于 Flask 实现多并发服务部署与负载均衡，完成模型顺利上线；
- 第二个版本重点优化“自然拟人化”，从文本与语音两个维度出发，文本维度：构建 1000 篇口语化的播客内容，然后基于 qwen3-8B 微调播客模型，最后使用 deepseek 纠正对话结构、错别字等问题；语音维度：筛选口语化的发音人，并补充 180h 优质口语化的语音数据，通过 vc 的方法转换到对应发音人。
- 使用 deepseek 完成标题生成模块；训练句级时间戳模型（自测准确率 100%）用于说话人切换，实现双人播客场景稳定上线，完成 DeepResearch 内容转播客技术验证，规划 2-3 个潜在扩展领域。

2022.07-2023.12 智能客服（快手）

项目介绍：公司每天有大量的客服热线，消耗大量人工，而热线中多数问题可以由机器自动回复，从而降低人力成本。我负责该项目中的流式 ASR 部分，项目上线后节省人力 100+。

- **效果提升：**1.从 chain 模型升级为 rnnt 模型，CER 降低 30% 2.使用模型预训练，CER 降低 15% 3. 使用 look-ahead 方法，模型看未来 640ms，CER 降低 10%；3.提出非流式 distill 流式方法，CER 再次降低 5%
- **降低延迟：**1.chunk size 从 16 降低到 4，降低延迟 480ms 2.encoder 上加入 phone 帧级别的分类 loss，降低延迟 100ms
- **优化判停：**提出将判停 vad 和 asr 模型放到同一个模型中，提高了 vad 准确率，并降低了判停延迟
- **解决误出字：**电话场景噪声较大，一些噪声导致 asr 误出识别结果。解决方法是收集噪声数据，加入到训练数据，使得模型对于噪声不出识别结果
- **热词：**为提升热词的召回，实现了基于 fst 的热词干预功能

2022.01-2023.12 自动字幕效果持续优化（快手）

项目介绍：字幕是 to C 的业务，字幕效果好坏能直接影响用户体验，也间接影响作品质量

- **优化识别结果:** 1. 训练数据从 1.7wh 提升至 5wh+, CER 降低 10%; 2.模型从 100M 提升至 180M, CER 降低 10%
- **降低延迟:** 1. 提出新的时间戳生成方法, 替代使用 chain 模型来生成时间戳, 新方法在 encoder 端输出 phone 分类, 然后将识别结果和 phone logist 做强制对齐生成时间戳
- **降本增效:** 1. 将 las, rnnt 双模型融合成一个模型, 共用 encoder, 减少计算量; 2.和其他部门合作, 重写 rnnt 和 rnnlm 引擎, 加速推理

2022.01-2022.09 多模态 ASR (快手)

项目介绍: 视频本身是丰富的多模态数据, 目前 asr 只用到了音频, 没有用文本和图像, 想利用其他信息进一步提高 asr 的准确率

- **模型结构:** 提出基于 AV-Hubert 音视频的预训练模型, 预训练模型生成音视频 Embedding, ASR 模型对 Embedding 进行 attention, 从而将音视频的多模信息引入 ASR。
- **效果:**在电商直播场景, CER 相对下降 3%

2022.01-2022.03 ASR 训练加速 (快手)

项目介绍: 随着训练数据越来越多, 模型越来越大, 训练速度成为制约算法探索和模型迭代的重要因素

- **数据加速:** 1.通过减小读取 buffer size、禁止系统预读等方法, 数据读取性能提升 50 倍, 不再成为瓶颈; 2.组 batch 改成 bucket 方式, 相似长度的数据放在同一个 bucket 中, 减小无效计算 50%; 3.变速前置: 组 batch 前确定变速速率, 使得 bucket 中变速后的数据长度相近, 减少无效计算 20%
- **计算加速:** 1. 使用混合精度训练, 提升训练速度和减少显存消耗; 2.解决 fp16 带来的训练稳定性问题; 3.使用 fused_adam, 融合 optimizer 中的算子减小计算开销
- **网络优化:** 1. 使用 fp16 通信, 减少一半的通信; 2. 梯度累加, 减少通信次数
- **收益:** 1.训练速度提升 5.8x; 2.8x8 卡相比单卡加速比达到 85%; 3.GPU 利用率从 40%提升到 95%; 4. 训练 5w 小时业务模型, 时间从 1 个月降低到 5 天

2019.6-2021.5 基于 LAS 的 ASR 训练平台 (字节跳动)

项目介绍: 为了提高 ASR 效果、降低模型运维成本、适应国际化业务发展的需求, 小组将 ASR 框架从基于 Kaldi-CTC 模型升级到基于 Tensorflow 的 LAS 模型

- **效果提升:** 1. 引入 Spec-Aug、MWER、模型平均、PSS 等算法, 在 Librispeech 上和 google 效果打平(test-clean 2.85/2.8, test-other 7.0/6.8); 2. 对于长音频(>60s), 提出 Audio-Cut 算法, 解决了长音频识别结果差的问题; 3. 对于模型识别纯音乐时乱出其他字的问题(例如:啊、抖音), 提出训练中加入纯音乐数据; 4. 为了提高引擎吞吐, 将 LSTM 模型升级为 Transformer 模型, ASR 识别效果相对提升 5%, 引擎吞吐提高 87%
- **训练加速:** 1.单卡加速:引入 CUDNN、混合精度,单卡速度提升 4 倍;2.多卡加速:引入 Horovod 和 BMUF, 8、16、32、64 卡加速比基本线性, 达到 0.9
- **功能完善:** 1.建模单元:为了解决国际化多种语言和 Multilingual 的建模单元问题, 引入了 google 开源的基于 WPM 的 sentencepiece; 2.时间戳自动生成:提出基于 CTC 的时间戳, 该功能用于字幕时间戳和审核关键词定位; 3.词/句置信度输出, 完成基于 Decoder-Softmax 的置信度输出, 该功能应用于视频搜索和国际化审核业务中, 该功能正在持续优化中; 4.自动打轴:提出并完成两次匹配的自动打轴算法, 该功能用于视频自动打轴
- **训练 pipeline:** 为了降低 RD 模型运维成本, 提出并完成了基于 CE→MWER→CTC 的训练 pipeline, 并和系统组合作, 将该 Pipeline 在网页上平台化, RD 只需在网页上填少量信息, 就可产出业务模型, 且可以方便了解训练进度以及监视中间模型效果
- **收益:** 该训练平台满足了现有的国内和国际化的审核和字幕业务的需求, 审核和字幕业务全部迁移到该平台基本满足了 RD 开发调试需求

2020.2-2020.8 数据标注流程搭建 (字节跳动)

项目介绍: 由于海外业务快速增长, 海外 ASR 需求持续增加, 为了加快海外数据标注的同时, 控制标注质量, 和另一个同事合作完成了海外数据标注的整个流程

- **标注规范:** 完成了相对通用的标注规范, 各个语言的规范只需语言专家稍作修改即可
- **数据处理流程:** 完成了数据源获取下载→AED→音频指纹→ASR 等数据处理流程
- **数据标注流程(同事完成):** 讨论出一套相对可行的标注流程: 初标-100%(外包)→质检-100%(外包)→评估-20%(外包交叉)→验收-2%(内部)
- **收益:** 该流程已完成了海内外 20+个语言上百万小时的数据标注任务