

杨玉杰

北京 | yangyj.m@outlook.com | 13121219985

个人简介

深度学习算法工程师，专注于大语言模型和多模态任务研究，致力于算法原理的持续探索与创新。
熟悉深度学习主流技术，熟悉大模型算法开发流程，具备丰富的大规模模型训练和优化经验。

教育经历

北京航空航天大学，工学学士 2015.09 – 2019.06
清华大学，人机语音交互实验室 (HCSI)，工学硕士，导师：吴志勇教授 2020.09 – 2023.06
• 研究方向: 语音识别，声学模型预训练等

工作经历

算法工程师，阿里巴巴，通义实验室， 2025.06 – Now

- 支撑 Omni 模型 CPT 和后训练，优化端到端 (E2E) 语音交互系统，主导语音理解侧能力优化，并协同提升语音生成能力。完成线上客服和角色扮演场景语音对话端到端方案从 0 到 1 的突破。
- 针对传统级联方案 (ASR+LLM) 的信息损耗问题，设计并实现了端到端语音理解架构。通过语音模态持续预训练与高质量指令微调，强化基座模型的跨模态对齐能力。模型相比同参数规模的 ASR+LLM 基线，端到端理解准确率提升 12%。
- 负责理解端离线强化学习对齐。构建了综合考量多模态对话历史 (文本 + 语音) 的 Reward 系统，通过 RL 显著提升模型对于语音交互中副语言信息的理解能力。

算法工程师，华为，诺亚方舟实验室， 2023.07 – 2025.05

深度参与了多个尺度的语言模型以及多模态模型预训练和后训练过程，熟悉大模型的性能优化，数据建设，模型训练，偏好对齐，模型评估等流程。此外对一些大语言模型中的先进技术进行过探索，例如线性复杂度模型、混合架构 MOE 及小模型参数继承等，一些工作产出为论文发表至 NeurIPS, NAACL。

- 日常维护盘古系列的基础语言模型的训练工作，熟悉模型结构，数据配比和预训练后训练流程。
- 深度参与 Pangu-Omni 项目中语音部分的研发工作。熟练掌握语音 tokenizer 相关的离散化技术，以及离散化语音 token 用于 TTS，多模态对齐等任务的方案。同时熟练掌握扩散概率模型相关技术，对基于 DPM 的连续语音特征建模方案理解深入。
- 构建了基于可学习的结构化剪枝来初始化较小模型参数的流水线。针对 MHA, GQA, 稠密和 MOE 的 FFN 等 Transformer 模块设计剪枝方案。由 7B 模型剪枝出的 3B 和 1.5B 小模型相比于基线收敛速度分别加速 60% 和 45%，并且收敛时 loss 明显更优。
- 训练并部署更小尺度的语言模型或模块为大语言模型投机推理加速。通过参数继承，同源数据微调，蒸馏对齐等方案提高小模型的接受率。在摘要翻译等下游任务达到 2.0-3.0+ 的加速比。在盘古训推框架中首先实现并验证 MTP 投机推理模块。
- 后训练过程中使用直接偏好优化 (DPO) 算法进行模型对齐，显著提升模型输出与人类偏好的一致性。主导偏好数据的采集与标注，设计了高效的数据采集流程，确保数据质量。离线阶段使用 DPO 算法完成对齐后的模型评测表现平均有 3-5 分位的提升。
- 独立主导 AI 合成语音检测项目，成功构建数据获取、算法设计、实验迭代全流程，并取得域外测试集 90%+ 准确率。

算法实习生，百度研究院，认知计算实验室 2022.08 – 2023.04

- 从动力学出发优化扩散概率模型的采样算法，在相同 NFE 时相比基线算法有提升。
- 在自动驾驶仿真系统使用 NeRF 算法进行场景渲染。在研究中使用了一种新的损失函数 S3IM，在多种

NeRF 框架中均有明显的提升。相关成果已发表至学术会议。

算法实习生, 华为, 诺亚方舟实验室

2021.11 – 2022.08

- 探索低资源场景下任意唤醒词的语音唤醒课题
- 提出针对唤醒词的声学模型自定义剪枝方案, 利用低质量数据训练声学模型, 在压缩声学模型 85% 参数同时提升精度。相关成果已发表至学术会议并进行专利成果转化。

算法实习生, 腾讯, 优图实验室, 深圳

2021.04 – 2021.08

- 研究多模态声学场景检测方案, 在 DCASE2021 比赛中获得赛道第四名
- 音频理解方案用于视频内容理解, 提升视频拆分准确率

文章发表

- Yang Y, Zhang K, Wu Z, et al. Keyword-specific acoustic model pruning for open-vocabulary keyword spotting[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP).
- Xie Z, Yang X, Yang Y, et al. S3im: Stochastic structural similarity and its unreasonable effectiveness for neural fields[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV).
- Yang Y, Qin H, Zhou H, et al. A robust audio deepfake detection system via multi-view feature[C]//ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP).
- He W, Han K, Tang Y, et al. Densemamba: State space models with dense hidden connection for efficient large language models[J]. arXiv preprint arXiv:2403.00818, 2024.
- Zhou, H., Tang, Y., Qin, H., Yang, Y., et al. (2024). Star-Agents: Automatic Data Optimization with LLM Agents for Instruction Tuning. Advances in Neural Information Processing Systems (NeurIPS), 2024.